具身智能推理性能评估与优化完整报告

实验成果、耗时分解与候选路线比较

GPT-as-Policy · bowl · RPent · DeepSeek

版本 v2.0 · 2026 年 10 月 14 日

性能评估以耗时为主线，比较优化方案时保持任务完成质量基本不下降。实验结果按各自任务、样本和计时边界呈现。

已完成的工作与主要发现

实验工作	关键性能结果	结论及适用范围
GPT-as-Policy 三任务三路线	9 条有效轨迹、610 轮决策、428 次 GPT 调用	罐子 Hybrid 每轮 18.82s，其中 GPT 约 14.37s。每轮审核带来显著等待，本批成功 Hybrid 均放行 Student。
bowl 同 seed 补测	Astra 平均 336.11s，Sol medium 547.09s，Sol ultra 600.63s	整集效率同时受单次等待与轮数影响。每组 5 集，不构成普遍模型排名。
RPent 正式 120 集	SDK 非工具 43.3%，动作执行合计 44.3%	高层调用链路与执行侧共同占据大头。SDK 区间包含请求、重试与编排。
RPent 独立深度 8 集	π handler 占 1.81%，原语内渲染占 40.05%	单独加速 π 前向对当前整集收益有限，局部控制实时性仍需另行检查。
DeepSeek 细粒度实验	v5 平均 TTFT1.82s、thinking 窗口 3.14s、decode 窗口 1.28s	同局不同轮次的瓶颈不同，均值必须结合长尾与上下文分析。

对优化方向的判断

单次耗时和调用轮数必须联合优化。 请求变快可能伴随更多恢复或重复动作；减少调用也可能使状态陈旧。比较方案时同时记录整集耗时、累计模型等待、请求数、全部重试成本和任务结果。〔E3，S1、S6–S8〕

low think 调整单次推理预算，JEV 改变部分决策的承担者，Astra/JEV 与 VLA 的分工改变调用频率和执行连续性。三类改动可组合，但不能直接相加提速比例。现阶段保留候选路线，通过固定请求和闭环任务两层实验比较。〔E3，设计〕

MT 反馈 thinking 由 4.6s 降至 1.4s，阶段降幅 69.6%。这是用户转述的最新实验结果，按 E4 独立记录。模型、样本量和阶段时钟尚未归档，因此不将其与历史 DeepSeek 结果合并，也不外推为整集降幅。〔E4，S16；计算 E3〕

1 评价指标与统一时间边界

以整集任务时间 T_episode 检验实际收益，以累计高层请求等待 T_request 和逻辑调用数 N 解释推理成本。串行链路可写为 T_episode = N × 平均逻辑请求等待 + 工具执行并集 + 其他独占开销。一次逻辑请求的等待应包含其重试与重连；并行或嵌套阶段按关键路径和区间并集记账。〔E3，方法〕

指标	本报告采用的解释	不能直接替代的量
TTFT	客户端发送/代理入口至首输出事件，按各源定义标记首 SSE 或首非空输出	纯 prefill 或纯排队时间
首输出前子阶段	代理准备、请求发送、到响应头、响应头到首输出等可观测区间	服务端 GPU/NPU kernel 计算
可见 thinking 窗口	源报告中首输出事件到首正文/工具输出的时间窗	完整 hidden thinking 或全部 reasoning 计算
正文/工具 decode 窗口	首正文/工具参数至响应结束的可见区间	服务端逐 token 时钟
token 分摊阶段	按 reasoning 与其他输出 token 占比分摊生成区间，明确标为估算	独立计时的 thinking/decode
TPOT	生成窗口与输出 token 数的派生值，保留源报告分母和聚合方式	逐 token 延迟分布或系统吞吐
动作原语 / π handler	父级原语含动作与观测，handler 含网络内部阶段	纯前向或所有控制时间

质量与可比性约束

比较速度时固定任务、初态、成功谓词、预算与工具接口。全部配对任务都报告结果，失败与基础设施异常分别记账。共同成功子集可用于解释时间变化，同时保留全量成功率和消耗，避免选择性展示。现有小样本不能证明成功率统计等价。〔E3〕

thinking 与正文/工具参数在服务端均属于 token 生成；本文将二者分开是为了定位可见输出成本。TTFT、thinking、decode 只有定义互斥、时钟一致时才能求和，父子 span 不得叠加。〔E3〕

证据等级：E1 为源码行号，E2 为配置，E3 为报告记载或推断，E4 为未复核转述。本文重述既有实验报告的数据标 E3；“实测窗口”描述源报告方法，不代表本次重新运行了实验。

2 已完成实验全景与证据分工

实验集合	完成范围	比较变量	主要证据用途
GPT-as-Policy LIBERO v2	3 任务×3 路线，9 回合	Direct / Student / Hybrid	决策轮数、请求阶段、π 与环境开销
bowl 原四批	Astra5，其他各 20	四模型，接入/并发不完全一致	早期完成能力与等待现象
bowl 同 seed 补测	4 组×5 seed，20 回合	Astra medium、Sol medium/ultra、Luna max	同 seed 整集耗时和轮数
RPent 正式评测	2 模型×3 套件×20，120 集	Astra / Sol medium	整体结果与互斥时间账本
RPent 深度计时	2 场景×2 模型×2 seed，8 集	独立插桩补测	render、physics、π 子阶段及请求尝试
DeepSeek 两场景	原 8 集与流式 8 集分开	medium / none	档位、TTFT、token 分摊与任务结果
DeepSeek v5 单局	15 轮，182.5s	Files API、流式代理等组合	逐轮请求、输出窗口、payload/cache
Files API 专项	11 轮，153.1s	文件引用及输入策略	独立优化尝试，部分时间为估算
后续审计新主例	15 请求，205.3s	新的流式分阶段记录	prep、headers、首输出与生成窗口
MT low think	样本量未提供	thinking 4.6s 至 1.4s	最新阶段反馈，E4

RPent 正式 120 集给出总体时间结构，深度 8 集解释执行侧内部组成，DeepSeek 补充请求链路与输出阶段。不同任务和批次各自保留分母，不将独立集合拼接成一个逐步优化的实验序列。〔E3，S5–S11〕

9/17 MuJoCo 与昇腾文档属于路线计划，RoboTwin2.0 与 π0.5 资料属于选型调研。JEV、异频 VLA 及本地 NPU 后续方案列为候选设计，其计划样本不计入已完成实验量。〔E3，S2、S9、S12–S15〕

来源 S1–S16。正式结果与补测分开；目录日期、文件名日期与文内版本不一致时，以报告文内版本及实验标识确定集合。

3 GPT-as-Policy：轮数与单轮成本

三任务各比较 Direct、Student、Hybrid，Astra 使用 medium，Student 为 π0.5。九回合共 610 轮决策、3008 控制步、428 次 GPT 调用。每格仅 init0 一条轨迹，部分运行并发，因此这些数值用于解释已观察轨迹，不构成隔离吞吐基准。〔E3，S1〕

任务	路线	结果	决策轮	整轮均值 s	episode s
两罐入篮	direct	成功	97	14.41	1428.97
两罐入篮	hybrid	成功	51	18.82	991.09
两罐入篮	student	成功	52	4.20	248.71
微波炉	direct	失败	105	17.36	1848.50
微波炉	student	成功	70	3.41	262.34
底层抽屉	direct	失败	64	19.11	1254.40
底层抽屉	hybrid	失败	60	22.43	1377.62
底层抽屉	student	失败	60	4.42	296.02
微波炉	hybrid	成功	51	19.65	1026.64

轮数减少与单轮变慢可能同时发生

两罐任务 Hybrid 只有 51 轮，Direct 为 97 轮，但 Hybrid 整轮均值 18.82s，高于 Direct 的 14.41s。Student 同任务 52 轮、均值 4.20s。对一条任务轨迹的效率判断，必须同时查看轮数和每轮等待。〔E3，S1〕

成功的两条 Hybrid 轨迹均为 51 次放行 Student，未展示 GPT 接管带来的成功改善；抽屉 Hybrid 接管 13 次仍失败。π 随机状态未配对，微波炉 Hybrid 含补跑，不能把轮数差直接归因于 GPT 纠错。〔E3，S1〕

整轮均值对应决策循环，episode 还包含初始化等边界外成本。不能用整轮均值乘轮数后替换原始 episode 值，也不能把仿真动作时长当墙钟耗时。〔E3〕

Direct 直接给控制目标，Student 执行 VLA 候选，Hybrid 在候选后等待 GPT 审核。来源 S1 v1.9，9/29。

3.1 GPT-as-Policy：请求与执行阶段

任务	路线	请求 s	TTFT s	可见窗口 s	TPOT 估算 ms/token
两罐入篮	direct	10.82	7.34	3.16	25.5
两罐入篮	hybrid	14.37	4.45	9.62	29.1
微波炉	direct	14.50	10.55	3.20	26.9
底层抽屉	direct	15.55	12.08	3.02	24.8
底层抽屉	hybrid	18.02	8.15	9.34	28.4
微波炉	hybrid	16.15	6.15	9.52	28.4

按请求统计均值。可见窗口为首至末非空 JSON 分片，含传输/缓冲；请求总时长另含收尾。thinking 时钟未独立提供。〔E3，S1〕

任务/路线	π 含同步 s	渲染读回 s	物理 s	环境墙钟 s
两罐入篮/direct	0.00	2.71	0.054	3.00
两罐入篮/hybrid	0.53	2.94	0.046	3.20
两罐入篮/student	0.55	2.77	0.052	3.05
微波炉/direct	0.00	2.27	0.028	2.48
微波炉/student	0.53	2.20	0.035	2.42
底层抽屉/direct	0.00	2.89	0.041	3.13
底层抽屉/hybrid	0.51	3.07	0.042	3.32
底层抽屉/student	0.53	3.10	0.041	3.35
微波炉/hybrid	0.51	2.24	0.033	2.46

罐子 Hybrid 的 TTFT4.455s 低于 Direct7.340s，但可见输出窗口 9.618s 高于 3.155s，最终请求反而更长。可见输出估计均值约 331.84 对 124.39 tokens/turn，说明首输出快不能替代完整结果快。该对照不能单独归因 thinking。〔E3，S1，计算〕

Student 没有 GPT 请求，TTFT 和 TPOT 记为不适用。GPT-as-Policy 的 TPOT 采用逐轮可见窗口/(输出−reasoning−1)，再取均值，与 DeepSeek 总输出口径分开。缺失 thinking 时钟不由 token 数反推为实测。〔E3〕

4 bowl：同 seed 效率与质量约束

9/23 补测使用 seed2005–2009 串行运行，每组 5 集。最大 20 次 LLM 调用、900 控制步，等待决策时物理暂停。此组保留整集 runner 墙钟、决策轮数和任务结果，不将墙钟除轮数冒充单次 LLM 请求时间。〔E3，S3、S4〕

模型/档位	自动入碗	平均轮数	平均墙钟 s
Astra medium	5/5	16.0	336.11
Sol medium	2/5	18.2	547.09
Sol ultra	3/5	17.6	600.63
Luna max	0/5	19.6	1969.76

主要性能发现

Sol ultra 比 medium 整集均值更长，但轮数略少，本批需要联合考察档位、轨迹和轮数。两档成功 seed 并非单向包含，不能从 3/5 与 2/5 断言提升档位总能提高完成质量。〔E3，S3、S4〕

自动入碗与稳定放置有边界差异，成功录像存在 stage3–4 边界。质量约束必须冻结相同终止谓词，并在需要时补充稳定放置确认。不能把不同验收标准的快慢作为方案优劣。〔E3，S3〕

可获取指标与缺项

指标	同 seed 补测	处理方法
轮数、runner 墙钟、控制步	报告提供	按各模型/档位分别展示
请求 TTFT、TPOT、thinking/decode	该补测未提供分段	保留未测，不用整集残差补齐
原四批单次等待与等待占比	另有摘要，统计子集未单独明确	单独标注来源及分母边界，避免混入补测
原四批自动入碗	Astra5/5、GLM0/20、DS1/20、Qwen4/20	接入、worker、并发与档位不同，仅作背景

耗时优化应守住闭环质量。更短 thinking 若导致定位误判、抓持判断失误或更多恢复，就可能增加整集时间。bowl 为这一约束提供背景，不能把其模型结果直接移植到 RPent 或真机双臂。〔E3，S3〕

S3 v1.2 更新至 9/23；S4 v1.1 包含模型身份更正。模型展示标签与实际派发身份分开审定。

5 RPent：120 集整体耗时与长尾

Astra 与 Sol 均为 medium，各 60 集，三套件各 20 集。120 集成功 99 集，Astra50/60，Sol49/60。以下耗时包含该集合中的失败和连接等待，描述实际运行成本。〔E3，S5〕

套件	Astra 成功	Sol 成功	Astra 均值/中位 s	Sol 均值/中位 s
Spatial Task	19/20	17/20	787.4 / 676.8	1248.6 / 811.6
Spatial Swap	20/20	20/20	586.9 / 560.0	943.7 / 828.9
Long Swap	11/20	12/20	973.7 / 919.5	1630.1 / 1332.8

总体量	Astra	Sol	解释
episode 累计	13.04h	21.24h	两线合计约 34.28h 工作量，非并行实验日历时间
成功数	50/60	49/60	总体相近，不能据此证明统计等价
明显长尾	按套件查看	Long Swap 一集 5348.4s	该轨迹包含连接中断等待，不全是模型计算

为什么同时报告均值与中位数

Sol Spatial Task 均值 1248.6s，中位 811.6s，差距提示长尾对平均完成时间有明显影响。只看最快成功案例会漏掉连接等待、重复执行和异常恢复；只看总均值又难以判断典型请求或典型任务的表现。〔E3，S5〕

正式集合先回答整体性能，再由深度补测定位子阶段。120 集没有全链路独立的服务端 prefill 或 hidden thinking 时钟，因此不能从均值差推断芯片吞吐或纯思考速度差。〔E3，S5、S6〕

模型比较应同时固定接入与编排条件。后续可以单列基础设施等待与任务内恢复，但已发生的等待仍要进入运行总成本，不能在快慢结论中悄然排除。〔E3〕

来源 S5 正式 120 集。冷启动/加载与 episode 内成本的区别见下一节。

5.1 RPent：互斥时间账本

时间桶	累计 s	占 episode	实际包含
非 π 动作原语	45327.6	36.7%	控制、环境 step、动作内观测等
π 动作原语	9367.1	7.6%	模型请求、动作 chunk 执行与往返
工具附加	12429.8	10.1%	工具外围、采集与协议开销
SDK 非工具时段	53394.0	43.3%	请求、输出、网络/排队、重试与编排混合
SDK 外壳	2889.9	2.3%	episode 内启动收尾等
合计	123408.4	100%	约 34.28h，VLA 加载 5.78h 另计

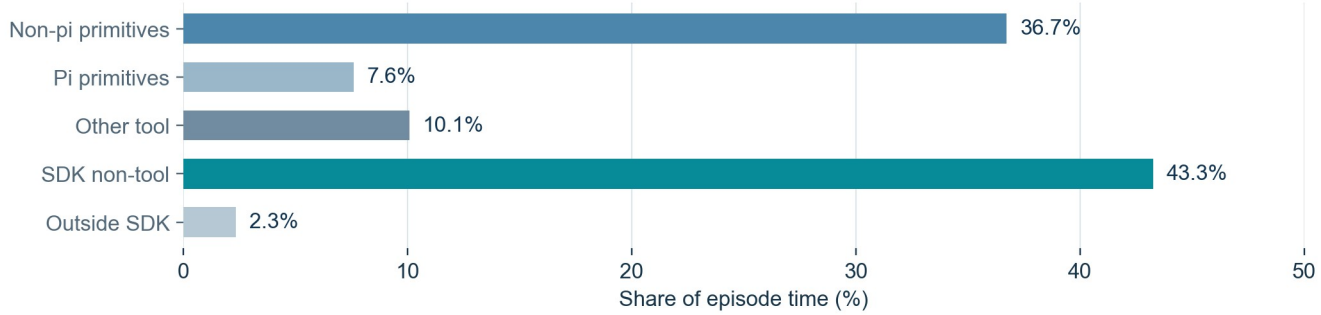


图 1　120 集互斥时间桶。按 S6 已报告秒数复算占比，显示值有舍入。〔E3〕

高层链路等待与动作执行并重。 SDK 非工具 43.3%，两类动作合计 44.3%。前者不能全部改名为 thinking，后者也不能全部改名为纯物理或纯 VLA 推理。定位优化对象需要继续拆分。〔E3，S6〕

π 动作原语只占 7.6%。固定轨迹且其他时间完全不变，即便该整桶清零，总加速上限约 1.082 倍；纯模型前向只占整桶的一部分，因此其整集收益上限更低。这个计算用于判断预算，不是实现收益。〔E3，条件计算〕

5052 条 usage 通知去重为 5014 个计量响应；它既不是全部 agent 消息数，也不保证覆盖全部真实传输尝试。不得用这个计数无条件反推单次模型延迟。

6 RPent：深度计时与 π 内部阶段

独立深度 8 集为 t0/t9×Astra/Sol×seed0/1，成功 3/8，其中 t0 为 3/4，t9 为 0/4。episode 累计 10965.30s。插桩补测的任务分布与运行条件独立于正式 120 集。〔E3，S7〕

阶段	累计 s	episode 占比	计时层级
原语窗内渲染	4391.18	40.05%	inclusive 子阶段
物理 step1+step2	121.48	1.11%	physics 子阶段
π handler，371 次	198.65	1.81%	包含 prefix、denoise 等
其中 prefix	96.19	0.88%	已包含于 handler
其中 denoise	86.14	0.79%	已包含于 handler
完整 π 动作原语	1110.09	10.12%	包含 handler 及动作执行
SDK 非工具	4187.54	38.19%	独占父级时间桶

prefix 与 denoise 分别占 π handler 约 48.4%和 43.4%，可用于安排局部 profile；二者不能再与 handler 相加。handler 均值约 535ms/次，由累计 198.65s 除 371 次派生，不能直接与不同探针条件的 384ms 前向基线比较。〔E3，S7，计算〕

假设 handler 全部处于关键路径且可加速一倍，固定轨迹最多节省约 99.33s，占这 8 集总耗时 0.91%。因此当前整集优化需要同时处理高层等待与重复执行，局部推理优化则应关注实时控制窗口。〔E3，条件计算〕

仿真边界

原报告将渲染排除出后续优化目标。扣除已测原语窗渲染后得到辅助量 6574.12s，SDK 非工具占其 63.7%。该辅助量不等于真机时间，真机仍有相机、控制器、通信和验证开销。〔E3，S7〕

仅 4 个 SAM 调用能匹配 client/server，不把共享服务全部活动计入本批。各阶段有包含关系，表格不能纵向求和。

7 RPent：轮数、重试与恢复成本

观察项	记录值	对性能分析的意义
逻辑调用与完整响应	448 次	一个逻辑调用可经历多个传输 attempt
传输尝试	473 次	比逻辑调用多 25 次，不能全部视为可删除浪费
Sol t0/seed1 恢复段	562.94s，含渲染 447.54s	非渲染剩余 115.40s，恢复影响多个阶段
Sol t9/seed1 恢复段	156.22s，含渲染 119.61s	非渲染剩余 36.61s
被排除 SAM OOM 尝试	2 个，episode 累计 3205.20s	不进正式 8 集分母，但属于已发生复现成本

决策轮数必须解释调用用途

一次高层调用可能用于读取说明、观察环境、定位、选择技能、恢复、写审计或结束。v5 的 15 轮中就包含前期资料读取和末尾审计。总请求数不能直接等同机器人动作次数，应按用途标记，再判断哪些调用可以合并、缓存或移到任务外。〔E3，S7、S10〕

减少一轮可能同时省去请求等待、工具调用和后续状态整理，也可能因缺少反馈增加失败。不能把某段恢复总时长全部视为可删除收益。已有数据尚不足以给出全批“无效轮次占比”，因此不制作未经证据支持的浪费占比图。〔E3〕

可比较的改动

改动	希望减少的成本	质量检查
任务前预载稳定指南	重复读取与启动请求	状态和规则版本一致
阶段结束后统一输出审计	任务内长文本输出	任务审计完整，可复现
进展检查与有限恢复	同一错误动作的重复尝试	抓持/位移/终止判据保持
复合技能与事件触发	细碎大模型往返	内部反馈、停止与回退仍执行

上述是由调用结构提出的候选改动，尚无受控提速结论。请求数、动作步数、额外验证与回退开销必须共同记账。〔E3，设计〕

8 DeepSeek：实验集合与计时精度

集合	规模与任务	可用细指标	主要限制
流式 medium/none	8 集，t0/t9 各 seed0/1	177 条有效 TTFT/TPOT，阶段 token 分摊	thinking/decode 分摊为估算，含失败请求
v5 单局	t2/s0，15 轮，182.5s	逐轮 TTFT 三段、可见 thinking/decode、payload、cache	TTFT 到首 SSE，是否首非空需保留定义边界
Files API 专项	t2/s0，11 轮，153.1s	TTFT、输入体积、token×常数阶段估算	独立实验，计时实现与 v5 不同
后续审计主例	object_swap t2/s0，15 请求，205.3s	prep、响应头、首输出、生成窗口，派生 TPOT	与 v5 同为 15 请求但不是同一轨迹
原始两场景 8 集	另一个独立集合	整集/请求/工具等原始口径	不与流式 8 集合并分母

三个层次的可用数据

第一层为请求总时长、首输出前等待和首输出后窗口。第二层为客户端可见事件分段，例如代理准备、响应头、thinking 到正文切换。第三层为 token 比例或平均速率推算的阶段量。各层均可用于分析，但必须标清测量方法。〔E3，S8、S10、S11〕

本报告保留“prefill 代理”这一解释性概念，但在表中优先写 TTFT 或客户端剩余区间。没有服务端计算 span 时，不能从该区间单独确定 prefill、排队或算子瓶颈。〔E3〕

客户端统计也能直接指导工程优化：传图高时检验输入复用，生成窗口高时检验输出长度和 thinking 档位，长历史下等待高时检验上下文策略。每项改动通过固定请求重放隔离链路效果，再通过闭环任务检查总轮数和质量。〔E3，设计〕

S8 v1.5 为后续审计口径；S10/S11 保留单局身份。不同实验配置、缓存与轨迹下的总时间不直接作优化前后差。

9 DeepSeek v5：典型请求与长尾

指标	均值	中位数	最大值/说明
TTFT	约 1.817s	1.07s	3.89s，首 SSE 口径
可见 thinking 窗口	约 3.143s	1.46s	19.96s
正文/工具 decode 窗口	约 1.280s	0.65s	8.94s
请求总耗时	约 6.240s	3.50s	24.5s，15 次累计约 93.6s
TPOT	未单列均值	约 4ms/token	报告范围 3–5ms，区间派生

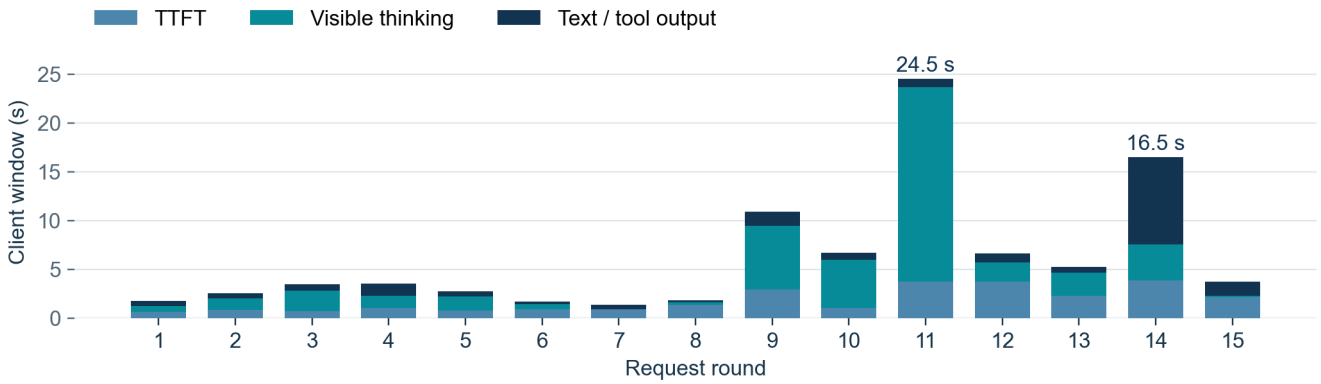


图 2　v5 十五轮客户端阶段窗口。第 11 轮 thinking 和第 14 轮正文/工具输出形成不同长尾，舍入使分段之和与请求总值略有差异。〔E3，S10〕

第 11 轮总 24.5s，其中 TTFT3.73s、thinking19.96s、decode0.86s；reasoning4491 tokens。第 14 轮总 16.5s，其中 TTFT3.89s、thinking3.69s、decode8.94s；其他输出 2687 tokens。两轮分别由不同生成窗口主导。〔E3，S10〕

均值明显高于中位数，意味着少数长请求影响累计等待。优化报告应同时给均值、p50 及长尾例子。15 个请求不足以稳定估计跨任务 p95，不能据此承诺一般模型延迟。〔E3〕

由源报告已舍入的逐轮表复算。thinking 和 decode 是客户端可见窗口，TPOT 不是逐 token 独立时钟。

9.1 DeepSeek v5：逐轮时间与输出规模

轮	TTFT s	think s	decode s	请求 s	reasoning tok	其他 tok
1	0.68	0.6	0.5	1.8	174	218
2	0.84	1.24	0.51	2.6	289	224
3	0.72	2.12	0.65	3.5	512	254
4	1.05	1.28	1.22	3.5	312	454
5	0.82	1.46	0.49	2.8	336	181
6	0.93	0.55	0.27	1.8	125	124
7	0.94	0.0	0.44	1.4	0	184
8	1.37	0.27	0.22	1.9	60	75
9	2.95	6.56	1.44	10.9	1572	569
10	1.07	4.93	0.75	6.7	1174	271
11	3.73	19.96	0.86	24.5	4491	280
12	3.73	2.0	0.91	6.6	437	354
13	2.33	2.38	0.56	5.3	557	187
14	3.89	3.69	8.94	16.5	890	2687
15	2.21	0.11	1.44	3.8	12	429

累计时间与任务时间

十五次请求累计约 93.6s，占 182.5s 任务墙钟约 51.3%。两者差额约 88.9s 应称工具及其他剩余时间；仅由残差不能证明全部为工具执行。源报告的“去掉 thinking 后约 135s”是在轮数与其他阶段不变下扣除约 47.15s 的条件估算，未实跑。〔E3，S10，计算〕

第 1–7 轮包含读取资料和目录等启动活动，第 14 轮包含写审计，第 15 轮为 finish。表中的轮次是模型请求轮次，不是 15 次机械臂运动。启动和收尾请求若被移出任务路径，应同时报告任务内耗时与完整运行成本。〔E3，S10〕

thinking 窗口的减少既可来自更少 tokens，也可来自生成速度变化。正文/工具输出同理。为了分析具体机制，下一轮应同时记录各类 tokens、阶段窗口和每请求 TPOT，而不是只比较一个平均延迟。〔E3，设计〕

本表为单局完整 15 请求性能摘要，不复制逐轮输入输出或隐藏推理内容。TTFT 源定义为到首 SSE chunk。

9.2 DeepSeek v5：输入、缓存与传输

TTFT 客户端分项	均值 s	p50 s	范围 s
代理传图/准备	约 0.663	0.03	0.00–2.26
chat 上传	约 0.695	0.61	0.36–1.24
源报告服务端剩余区间	约 0.460	0.44	0.24–0.76

轮	prompt tok	新增/总图	请求 KB 原→转发	cache	TTFT s
1	13,094	0/0	50→57KB	64%	0.68
8	60,306	0/0	214→221KB	64%	1.37
9	62,344	3/3	2172→223KB	97%	2.95
11	69,229	3/6	5820→240KB	96%	3.73
14	81,015	3/13	10105→267KB	97%	3.89
15	84,686	0/13	10118→280KB	100%	2.21

新图轮 9、11、14 的代理传图分别约 1.87、2.24、2.26s，说明文件引用并未消除新增图上传。末轮总图保持 13 张，源表代理准备仍为 0.47s，列名不能机械解释成纯图片网络传输。〔E3，S10〕

方案将 base64 替换为 file_id，并同时禁用图片裁剪、保留历史和转换为流式。请求体明显缩小，但这些因素共同变化，不能从一条轨迹证明 Files API 单因素的端到端收益。文件引用减少请求载荷，也不必然消除服务端视觉计算。〔E3〕

prompt 从 13094 增长至 84686 tokens，cache 展示值 64%–100%。该单局中的剩余区间相对稳定，不足以证明 prefill 与 prompt 长度、图像数量无关。表中“prefill 吞吐”也不能直接解释为服务端 token 处理能力。〔E3，S10〕

分项中位数一般不相加为总 TTFT 中位数。建议固定请求重放时分开新图/复用图、冷/暖缓存，并保持语义、图像和输出预算相同。〔E3，设计〕

10 DeepSeek：medium 与 none 闭环对照

共同成功 t0	medium	none	差异
seed0 episode	1497.8s	1043.1s	下降 30.4%
seed1 episode	828.9s	805.1s	下降 2.9%
episode 累计	2326.7s	1848.2s	减少 478.5s，20.6%
逻辑请求数	63	57	减少 6 次
LLM 累计	1238.435s	715.819s	减少 522.616s
TTFT 累计	776.094s	607.904s	减少 168.190s
thinking 估算	352.550s	0	按输出 token 比例分摊
其他 decode 估算	97.379s	107.915s	增加 10.536s
失败请求耗时	12.412s	0	单列，无独立阶段数据

medium 与 none 各 4 集，均在 t0 两个 seed 成功，t9 两个 seed 未完成，成功率均 2/4。medium 的 t9 发生输出预算异常退出，none 虽无该进程异常仍未完成任务。相同小样本成功数不构成质量非劣性证明。〔E3，S8〕

关闭 thinking 改变了输出、上下文、轮数与动作轨迹，且两档 prompt 并非逐字相同。累计整集节省 478.5s 不能全部归因 thinking 计算。分 seed 收益差距也表明结果受具体轨迹影响。〔E3，S8〕

估算方法与真实时钟

源审计令 τ=(请求总时长−TTFT)/输出 tokens，再按 reasoning 与其他 token 数分摊生成区间。该 τ 与采用输出 tokens−1 分母的 TPOT 分开记录。失败请求没有分段数据时仅保留总时长。〔E3，S8〕

四条成功轨迹共 120 个逻辑请求、121 个 attempt；整个流式 8 集为 177 个逻辑请求、178 个 attempt，TTFT/TPOT 各 177 条有效记录。

10.1 DeepSeek 流式 8 集：请求分布与输入规模

场景/档位	请求 mean s	请求 p50 s	TTFT mean s	TTFT p50 s	TPOT p50 ms/token
t0_s0/medium	23.19	20.72	13.89	12.50	7.309
t0_s1/medium	14.09	13.77	10.08	10.22	4.602
t9_s0/medium	14.32	9.79	6.70	5.57	4.568
t9_s1/medium	21.64	17.28	7.01	5.16	5.393
t0_s0/none	13.86	12.34	11.33	10.39	5.183
t0_s1/none	11.00	11.91	9.87	10.67	3.526
t9_s0/none	7.60	6.83	5.03	4.81	3.282
t9_s1/none	13.95	9.06	7.06	5.76	4.455

请求统计按每集传输 attempt 记录，含失败请求的总时长；TTFT/TPOT 仅用有效记录。每集样本不同，不能直接对各行均值作无权重总体平均。〔E3，S8，源表复算〕

场景/档位	逻辑/attempt	input 总 tok	reasoning tok	最大输入 tok	最大图片数
t0_s0/medium	37/37	2,860,042	30,162	110,752	11
t0_s1/medium	26/27	1,239,193	15,456	68,807	14
t9_s0/medium	15/15	627,052	17,179	67,263	7
t9_s1/medium	11/11	557,028	23,484	81,821	6
t0_s0/none	31/31	1,352,875	0	62,277	13
t0_s1/none	26/26	1,015,692	0	52,786	13
t9_s0/none	14/14	446,189	0	43,277	6
t9_s1/none	17/17	633,602	0	61,223	14

input 总量重复计入每轮携带的历史，不等于唯一任务信息量。reasoning 计量为 0 与可见窗口为 0 均不证明服务端没有其他内部计算。t9 失败和预算退出保留在该表，以便完整描述负载与成本。〔E3〕

原始非流式 8 集未并入。prep 缺失不补 0，thinking/decode 缺窗口时不强制配平。

11 DeepSeek：后续主例的真实客户端分段

审计新增 object_swap t2/seed0 主例为 15 请求、205.3s。LLM 累计 110.534s，其中首输出后 88.796s，占 80.3%。该轨迹与 v5 的 15 轮 182.5s 分开统计。〔E3，S8〕

互斥客户端阶段	累计 s	占 LLM 约	解释
代理准备	5.110	4.6%	准备/转发前区间
请求阶段至响应头	9.789	8.9%	含发送与服务等待等
响应头至首输出	6.837	6.2%	首非空输出前的剩余等待
首输出至结束	88.796	80.3%	可见生成与传输区间
合计	110.532	100%	与报告总量 110.534s 相差 0.002s 舍入

辅助指标	数值	聚合与边界
TTFT 累计 / p50	21.739s / 1.270s	首输出前等待，占 LLM 约 19.7%
TPOT p50	3.931ms/token	每请求均值的中位数，分母输出 tokens−1
可见 thinking 窗口	14 个非零窗口累计 68.663s	另 1 条为 0，共 15 条；非 hidden thinking
对照：流式成功 4 集	TTFT1383.998s / LLM1954.254s	TTFT 占 70.8%，属于另一任务集合

同一个模型服务的瓶颈占比会随任务、历史、缓存、输出长度和轨迹变化。一组主要等待首输出，另一组主要耗在首输出后，二者可同时成立。不能把任一单局比例写成 DeepSeek 的固定性能特征。〔E3，S8〕

此类客户端时间分段适合判断工程改动作用于哪个区间。若要区分服务排队、prefill 与芯片执行，还需要服务端 span 或独立受控测量。〔E3〕

12 DeepSeek 专项：可比较的观察与收益

集合	总时间/轮数	请求与阶段指标	可支持的观察
Files API 专项	153.1s / 11 轮	逐轮表请求均值 9.136s、TTFT5.251s；thinking2.136s、decode1.755s 为估算	摘要和逐轮表使用不同阶段估算口径
v5 单局	182.5s / 15 轮	请求均值 6.24s；TTFT1.817s、可见 think3.143s、decode1.280s	用窗口与逐轮长尾解释时间结构
后续审计主例	205.3s / 15 请求	LLM 累计 110.534s；首输出后 88.796s	细分客户端发送到首输出与生成阶段

能够保留的技术信息

Files API 概览用 3ms/token 推得 thinking 约 1.6s、decode 约 1.3s；11 行逐轮表采用约 4ms/token 的口径，阶段均值为 2.136s 和 1.755s，请求总时长累计 100.5s。概览 8.2s 不是逐轮表均值。本文以逐轮表展示，并保留两套口径的差异。〔E3，S11，复算〕

Files API 局报告 3 次冷/暖探针约 1.45/1.0s，代表该探针条件，不足以把其他请求超出的全部时间解释为排队。文件引用和稳定前缀可能降低重复传输或改善缓存，但仍需同内容重放测量。〔E3，S11〕

v5 的 Files API、禁裁剪、历史保留和流式转换同时改变；153.1s、182.5s 和 205.3s 分别属于独立轨迹。不能把这三个总时间连成优化前后的曲线，也不能把轮数差直接视为某个开关的收益。〔E3，S8、S10、S11〕

候选改动与验证方法

候选改动	固定请求层	闭环任务层
文件引用/内容哈希复用	同图像、同语义、同缓存条件比较 prep 和 TTFT	检查视觉信息、历史完整性与任务质量
精简正文/审计输出	比较非 reasoning tokens 与生成窗口	保留必要工具参数与审计完整性
稳定前缀/状态摘要	观察实际 cache、输入 tokens 及 TTFT	检查历史遗漏导致的恢复与失败
thinking 档位	比较请求窗口、tokens 与长尾	检查轮数、动作数及全部 attempt 消耗

Files API 局中“11 轮降 8 轮” “153s 降 92s”和 v5 中“去 thinking 后 135s”均属于条件推演，未作为已完成实验收益。

13 综合瓶颈：证据与优化作用环节

问题	主要证据	可比较的优化	当前不能承诺
高层调用链路等待	RPent120 SDK 非工具 43.3%；GPT 罐子 Hybrid 请求占整轮 76.4%	档位、输入复用、输出压缩、选择器替换	全部是 thinking 或纯 prefill
生成窗口长尾	v5 第 11 轮 think19.96s，第 14 轮其他输出 8.94s	阶段化 thinking 预算、减少冗长输出	关思考必然保持轮数和质量
调用与恢复频率	深度 8 集 448 逻辑调用/473attempt，恢复跨多个阶段	复合技能、进展检测、事件触发	固定比例的轮次均可删除
执行与观测开销	RPent120 动作 44.3%，深 8 渲染 40.05%	减少重复执行，优化技能边界	仿真扣渲染等于真机时间
局部动作实时性	固定帧 π 探针约 384ms，5 步 20Hz 窗口 250ms	异步调度、chunk 设计、局部 profile	前向占整集小就无需优化

为什么单次耗时与轮数必须联合看

令一次逻辑请求平均等待为 L、请求数为 N、动作与其他独占开销为 A，串行近似 T=NL+A。单次等待降低 r 后，只有在新增轮次和额外动作成本没有抵消节省时，整集才会更快。若只考虑请求项，N_new/N_old 必须小于 1/(1−r)才能保留该项收益。〔E3，条件模型〕

不同改动的收益可能重叠：减少轮次会同时减少 TTFT 和生成窗口；压缩历史可能改变缓存与回答；JEV 可能需要 Astra 先生成候选。总收益应通过完整组合实验测量，不能把单因素百分比直接相加。〔E3〕

瓶颈判断分两个层级：当前轨迹时间大头决定整集优化空间，局部 deadline 决定控制是否连续。两者都要报告，但采用不同验收指标。〔E3〕

14 low think：阶段收益与质量约束

MT 最新实验反馈 thinking 由 4.6s 降至 1.4s。来源是用户 2026 年 10 月 14 日转述，模型、样本量、统计量与时钟尚未附齐，保留为 E4 阶段反馈。它与 DeepSeek medium/none 属于独立证据。〔E4，S16〕

阶段指标	数值	含义
差额	3.2s	4.6−1.4
降幅	69.6%	只针对该 thinking 指标
加速比	约 3.29 倍	不代表整集加速比

若 4.6s 与 1.4s 是同条件每请求均值，且轮数、工具与其他请求阶段不变，则 T_low=T_base−3.2N。若该 thinking 阶段原占整集比例为 f，整集降幅为 0.69565f。下面为条件预算，非已跑成绩。〔E3，基于 E4 计算〕

原 thinking 占比	整集时间降幅	整集加速比
10%	约 7.0%	1.075 倍
30%	约 20.9%	1.264 倍
50%	约 34.8%	1.533 倍

如何判断是否值得采用

固定请求比较 baseline/low 的 TTFT、可见窗口、输出 tokens 和请求 p50/p95，再在配对闭环中比较成功、轮数、恢复与全成本。质量基本不下降是采用前提，不能把速度改善补偿失败率上升默认视为可接受。〔E3，设计〕

可比较全程 medium、全程 low 和按阶段切换三种策略。阶段切换需要预先定义触发条件及回退，不能在看到失败结果后人工调整规则再合并统计。none 是另一个档位，不能代替 low 的实测。〔E3，设计〕

需归档的实验字段包括模型/版本、档位、任务/seed、重复数、缓存/并发、阶段起止时钟、请求总时长与任务结果。信息缺口不影响保留反馈，但限制承诺范围。

15 优化候选方案横向比较

方向	主要作用	收益依据	主要代价/风险	验证重点
low think	降低单次生成成本	MT 阶段反馈与 DS 档位相关证据	错误/恢复可能增加	配对成功、轮数及总耗时
JEV 选择器	替换部分有限选项决策	本地接口与结构化候选实现	状态/候选生成、回退及新增网络成本	固定同一候选比较规则/Astra/JEV
Astra+VLA 调用优化	低频规划与连续局部动作	RPent 已有 π 技能，GAP 每轮审核代价高	反馈频率下降、动作偏差积累	事件触发、复合技能与进展确认
Astra+JEV+VLA	规划、快速选择与执行分层	架构假设，尚无 RPent 受控收益	多层串行、陈旧状态和系统复杂度	新增选择器收益是否覆盖额外成本
请求/输出工程优化	输入复用、前缀稳定、输出缩短	v5 payload 与长输出观察	信息遗漏、缓存改变与审计不足	固定重放及闭环质量双重验证

比较顺序与路线选择分开

首先用固定请求分离单次成本，再用同任务闭环观察轮数与动作变化。低成本、易隔离的实验可以先做，但不意味着提前认定某条最终架构最优。当前证据不足以对 JEV 或完整三层组合给出可信提速百分比。〔E3〕

low think 可与不同决策架构叠加。JEV 的候选选择和 Astra 的视觉规划也可能共存。为了定位贡献，先单因素消融，再测组合，最终根据质量约束下的总耗时、长尾与工程成本比较。〔E3，设计〕

本节给出候选比较，没有确定采用路线。已测结果、源码能力与拟议结构分别保留证据等级。

16 JEV：职责、接入成本与证据边界

本地 embodied-jev 参考项目通过 TypeSafe System One API 发送文本 state 与 questions，取得 choice 与 probabilities。仓库未提供可直接移植到 NPU 的 Jev 权重与可审查的服务端网络参数。Jev 在这里承担有限候选选择，并非视觉动作模型。〔E1/E3，S12、J1〕

链路环节	已有参考实现	RPent 候选集成
视觉与候选	libero_v2 由 Astra 处理视觉并生成 2–3 个候选	计入视觉理解、状态整理和候选生成成本
决策选择	Jev 或 GPT 从候选中选择	技能 ID、恢复分支、重新观察或停止
执行	该 libero_v2 使用数值伺服	沿用 π 技能及已验证动作原语
反馈	环境状态与规则检查	任务进展、抓持、终止和异常回退

如果每次 JEV 选择前仍要调用 Astra 生成候选，就形成串行新增请求。只有当它减少后续请求、错误或恢复，或替换更昂贵的选择步骤时，整体才可能获益。评价对象必须是完整链路，不能只比较 selector API 延迟。〔E1/E3〕

上游单次开发案例中 drawer 从 GPT609.8s、112 请求变为 hybrid319.7s、75 请求，但小样本组内 GPT 为 2/2、hybrid 为 1/2，条件不构成受控非劣性比较。该结果可用于提出假设，不能移作 RPent 预期收益。〔E3，S12〕

固定候选消融保持同一 state、候选、硬约束与执行器，只更换规则/Astra/JEV 选择器。再逐步开放动态候选和回退，记录候选生成调用率、回退率、候选覆盖和新增等待。probabilities 需校准，不能直接当任务成功概率。〔E3，设计〕

J1 固定 commit f08de2e4e20d6cd69fea9c57ac1062c3ef510f1e；policies.py 277–422 为 API，libero_supervisor.py 101–289 为候选/选择/伺服。

17 Astra、JEV 与 VLA 的架构比较

架构	职责与调用方式	潜在优势	需要验证的代价
现有 Astra+技能/VLA	Astra 调用工具及 π 原语，执行后获得反馈	已有完整 RPent 基线	高层等待、碎片化调用与恢复
Astra 低频规划+VLA	技能内连续执行，在阶段边界/异常时请求高层	减少高层往返，维持局部反馈	技能覆盖、停止规则与观测新鲜度
JEV 选择+VLA	结构化状态和有限候选可直接提供时，由 JEV 选技能	低成本有限决策的可能性	独立视觉/状态构造、复杂情况回退
Astra+JEV+VLA	Astra 更新目标或候选，JEV 选分支，VLA 执行	分配复杂规划与常规选择	串行层数、同步成本、收益能否覆盖接入开销

共同的闭环要求

局部控制持续观察抓持、位移和安全边界，高层按可解释事件触发。事件包括子目标完成、对象/任务变化、连续无进展或状态置信不足。减少高层调用不意味着省略局部反馈与停止检查。〔E3，设计〕

用观测时间戳、技能版本与请求 ID 关联状态和动作。异步高层结果返回后先检查是否过时，再决定接纳、丢弃或在 chunk 边界切换。记录观测年龄、buffer 欠载、取消与回退次数，才能判断架构是否改善实时闭环。〔E3，设计〕

chunk 变长可摊销推理，却可能推迟纠错并增加恢复成本。比较时同时保持权重、动作范围与终止条件，报告单 chunk 时延、实际执行步数和任务质量。〔E3〕

Astra+π 技能已在 RPent 实验中使用；此处待比较的是调用频率、技能粒度、异步调度与 JEV 职责变化。

18 技术趋势与局部实时性

方向	本项目证据/相关研究	技术判断
分层决策与动作	GPT 逐轮审核等待、RPent 技能执行；HiRobot/Helix	高层语义规划与局部动作可以采用不同频率，关键是可靠的技能反馈
按阶段配置推理预算	DeepSeek 档位对照、MT low 反馈	普通阶段与异常恢复可比较不同预算，验收仍看完整任务质量
稳定上下文与输入复用	v5 payload/cache 和输出长尾	压缩与复用需保持任务信息，缓存命中率不是纯 prefill 时钟
异步 action chunk	π 延迟与动作窗口；RTC 研究	必须测延迟、观测年龄和动作连续性，不能仅看平均 token 或 action 速率

π 的整集占比小，仍可能超过控制窗口

v5 固定观测帧的 10 次独立 π 探针为 383–384ms/chunk，每 chunk 输出 5 步。按 20Hz 动作周期，5 步覆盖 250ms，小于 384ms 推理延迟。76.8ms/action 只是摊销量，不能解释为满足 50ms 控制周期。〔E3，S10，计算〕

独立探针与在线 handler 的观测、同步与插桩条件不同，不直接用两者数值比较设备性能。前向与等待分离后再 profile prefix、denoise、attention、搬运和同步，确认热点在关键路径。〔E3，S7、S10〕

云端 Astra/JEV 的服务排队和 kernel 不在本地可控范围。本地 NPU 路线需要可部署模型与实际算子 profile；32 次固定请求方案仍是计划，不能写成已有 NPU 吞吐结论。〔E3，S14、S15〕

技术趋势依据 S12–S15 及附录 W1–W3，不等于本项目完成真机验证或完整组合复现。

19 对照实验与结论收口

实验层	控制变量	主要输出	通过条件
固定请求重放	模型版本、输入、图像、缓存/并发、输出预算	TTFT、客户端子阶段、tokens、TPOT、请求 p50/p95	明确改善哪个窗口，保留输出正确性
闭环配对任务	任务/seed、工具、VLA 权重、预算、成功谓词	成功率、整集时间、请求数、恢复、全部 attempt 成本	质量基本不下降，时间收益覆盖额外调用
选择器消融	同 state、候选、硬约束与执行器	规则/Astra/JEV 的完整链路比较	包括状态构造、候选生成及回退
调度消融	同权重、动作范围、任务与停止规则	同步/异步、chunk、观测年龄、deadline	任务质量及动作连续性均满足要求

质量约束由冻结任务标准落实。预注册统计检验方法、允许的测量误差与样本规模，不擅自把 5 个百分点下降写为可接受门槛。小样本筛选可发现问题，但成功数相同不等于非劣性成立，扩大样本应依据任务差异与不确定性。〔E3，设计〕

当前可以成立的结论

性能诊断： RPent 总体时间由高层调用链路和动作执行共同主导；深度补测显示 π handler 对整集的占比较小。DeepSeek 不同集合分别表现为首输出前等待或首输出后生成占主导，阶段和上下文信息决定归因。〔E3，S6–S11〕

优化比较： low think、请求工程优化、JEV 选择器和 Astra/VLA 职责调整分别作用于不同环节。现有证据支持开展对照，尚不支持宣布统一赢家或承诺固定整集提速。以完成质量基本不下降为前提，联合比较单次等待、轮数、恢复和全成本。〔E3/E4〕

本报告汇总既有实验与源码，未新增远程仿真、训练或机器人运行。后续实验设计不计入已完成工作量。

附录 A 其他基线的 tokens、缓存与等待

GPT 任务/路线	输入 mean tok	总输出 mean tok	reasoning mean	可见输出估 mean
两罐入篮/direct	41772.9	160.81	36.42	124.39
两罐入篮/hybrid	44651.6	331.84	0.00	331.84
微波炉/direct	43787.5	159.66	39.96	119.70
底层抽屉/direct	33226.4	177.38	54.20	123.17
底层抽屉/hybrid	52864.7	333.32	3.05	330.27
微波炉/hybrid	47940.3	336.86	0.31	336.55

罐子 Hybrid 切片	input mean	缓存 mean	TTFT mean s	可见窗口 mean s
首 12 轮	21494	19040	4.38	9.57
末 12 轮	67806.5	66475	4.90	9.61

第一张表的均值按 S1 累计/GPT turn 数派生，输出总数已含 reasoning。缓存切片来自 S1 §6.4，只描述首末各 12 轮，不能替代全 51 轮，也不能单独证明 prefill 无成本。〔E3〕

bowl 原四批	决策等待 mean s	等待占比	统计边界
Astra	27.2	94.6%	原批仅 5 例
GLM	约 117，源报告推算	未提供	等待统计子集未单独明确
DeepSeek	135	99.2%	等待统计子集未单独明确
Qwen	约 110，源报告推算	未提供	等待统计子集未单独明确

bowl 旧等待指标包含模型与接入/调度等成本，不能写成纯 API latency。原表仅 trial 墙钟列明确前 5 配对，等待值不能擅自套入 9/23 同 seed 补测；原四批 token 来源也不同，不作费用或服务器吞吐推算。〔E3，S3〕

附录 B RPent 计量负载与 v5 同局口径复核

模型/套件	计量响应数	input 总量 M	cache 占 input	output 总量	reasoning 总量
Astra/Long Swap	893	75.820	96.7%	137,319	20,509
Astra/Spatial Swap	579	33.502	95.1%	92,009	10,559
Astra/Spatial Task	640	39.801	95.8%	94,601	9,339
Sol/Long Swap	1173	101.169	96.9%	207,605	75,942
Sol/Spatial Swap	865	58.435	96.1%	161,138	56,336
Sol/Spatial Task	864	57.890	96.1%	148,583	47,527

统计按 120 集报告中的计量响应累加，cached 是 input 子集，reasoning 是 output 子集。高缓存比例不等于短 TTFT，原集合没有可独立归因的 TTFT、TPOT 和纯 prefill/hidden-thinking 时钟。〔E3，S6〕

v5 旧表与后续审计属于同局的口径复核

v5 指标	原报告逐轮舍入表	后续审计 ds_v5
请求累计	约 93.6s	93.592s
TTFT 累计 / p50	27.260s / 1.07s	27.256s / 1.068s
可见 thinking 累计	47.150s	47.144s
正文/工具窗口累计	19.200s	19.192s
TPOT p50	约 4ms，原概览近似	3.621ms，按(总−TTFT)/(output−1)派生

两份公开表按 15 行顺序的 input、reasoning、output 等逐项对应，时间差与旧表舍入一致，作为同局口径复核，不增加实验数量。没有重新做原始 trace 的逐字节身份校验。TPOT 分母和聚合方式不同，保留各自定义。〔E3，S8、S10，复核〕

M 表示百万 tokens。缓存比例以全集合累计 cached/input 计算，不是每请求比例的无权重均值。

附录 资料索引与版本

路径以工作区根或 embodied-ai 仓库根为基准。S1–S15 为既有文件，S16 为本次用户补充。报告采用来源标题、版本与章节定位，不复制原始会话、凭据或运行端点。

编号	资料与位置	本文用途
S1	GPT-as-Policy-repro/data/decision_v2_20260922/index.html 多任务逐轮决策实录 v1.9，9/29	§5–§8 及内嵌九回合汇总
S2	GPT-as-Policy-repro/2026-09-17-GPT-as-Policy 在 MuJoCo 与昇腾上的复现计划.md	计划与执行范围区分
S3	weeks/2026_0914-0920_GPT6Astra 评测复现/2026-09-16-bowl-eval-v1 四模型总结报告.html v1.2，实际更新 9/23	§2、§3、§5
S4	weeks/2026_0921-0927_同机仿真与云边验证/2026-09-23-GPT6-Sol-bowl 五次与 Astra 同 seed 对照.md v1.1	模型身份更正、配对结果
S5	weeks/2026_0928-1004_RPent 双脑对照与回馈/2026-10-01-RPent-Codex 双模型 120 集结果.md v1.0	正式身份、成功与耗时
S6	weeks/2026_1005-1011_RPent 推理性能分析/2026-10-08-RPent-120 集推理耗时与优化报告.html v2.0	互斥五桶、响应计数与归因边界
S7	weeks/2026_1005-1011_RPent 推理性能分析/deep-report/RPent-两场景深度计时报告.html	8 集计时及敏感性预算
S8	weeks/2026_1012-1018_RPent 多模型性能分析/ds-report/RPent-DeepSeek-两场景性能审计.html v1.5	medium/none、分段口径与新主例

本文 E3 表示本次按报告记载复核汇总，不否定源报告曾完成实测；E1 仅用于已查看的代码接口与实现事实。

附录 选型资料与新增证据

编号	资料与位置	用途与限制
S9	GPT-as-Policy-repro/2026-09-21-RoboTwin2.0 双臂测评集与 π0.5 微调权重调研报告.md	选型调研；不同训练数据/任务范围的数字不作代际收益
S10	rpent-repo/ds_flash_v5_report.html 真实 TTFT v5，2026-10-11	15 轮 182.5s 专项；保留客户端测量边界
S11	rpent-repo/files_api_report.html Files API 优化局，2026-10-10	11 轮 153.1s 独立实验；旧计时推断以 S8 审计限制
S12	weeks/2026_1012-1018_RPent 多模型性能分析/2026-10-13-EmbodiedJev 项目分析与 RPent 对比.md	Jev 接口、选择器和执行器分工
S13	同周/2026-10-13-VLM-VLA 双脑架构与推理优化调研.md	架构、异频调度与受控消融
S14	同周/2026-10-13-具身 VLM 推理的芯片加速单元与验证路径.md	计算单元与 profile 路径
S15	同周/2026-10-13-910B3 本地 VLM 首批 32 次推理基线执行方案.md	32 次固定请求实验计划，非已跑性能
S16	2026-10-14 用户补充：MT 的最新 low think 实验反馈，think 4.6s 降至 1.4s	E4；待附配置、样本量、阶段时钟与任务结果

源码与官方资料

J1 固定版本 FBddcz/embodied-jev@f08de2e4e20d6cd69fea9c57ac1062c3ef510f1e。policies.py 第 277–422 行：API 请求与返回；libero_supervisor.py 第 101–289 行：视觉候选、selector 与数值伺服；policies.py 第 509–534 行：本地 MiniCPM 候选 logits 路径。〔E1〕

J1 EmbodiedJev 固定源码与接口

J2 TypeSafe System One 与 Models 官方说明

W1 Hi Robot 论文 2025

W2 Figure Helix 官方技术说明 2025

W3 Real Time Execution of Action Chunking Flow Policies 2025

官方资料访问日 2026-10-14。J2 与 W1–W3 均为 E3 文档/论文证据，支持接口和技术方向判断，不构成本项目性能复现。