具身智能推理性能评估与优化完整报告

GPT-as-Policy · GPT-6 Astra · RPent · DeepSeek
实验结论与 low think JEV VLA 路线评估

版本 v1.0 · 2026 年 10 月 14 日

覆盖 GPT-as-Policy、GPT-6 Astra bowl、RPent 双模型与 DeepSeek 性能实验，并评估 low think、JEV 决策和 Astra/JEV + VLA 的后续路线。

核心结论

优化目标应同时覆盖单次请求耗时与决策轮数。 RPent 120 集的动作执行占 44.3%，SDK 未覆盖工具的时段占 43.3%。后者含模型请求、网络、排队、重试与编排，不能全部归为 thinking。单独加速 π0.5 网络只能改善当前总耗时的一小部分。〔E3，S5–S7〕

已完成的实验建立了闭环基线，但尚未证明每轮大模型审核能稳定提高 VLA 成功率。 GPT-as-Policy 九轨迹中的两条成功 Hybrid 轨迹均全程放行 Student，抽屉任务发生 13 次接管仍失败。RPent 120 集总体成功 99/120，主要弱项是 Long Swap。〔E3，S1、S5〕

low think 已有新的阶段性反馈。 MT 最新实验报告 think 耗时由 4.6s 降至 1.4s，即该指标下降 69.6%、加速约 3.29 倍。该数据由用户转述，尚未附模型、样本量和阶段定义，按 E4 保留。它与历史 DeepSeek medium/none 对照属于两份独立证据。〔E4，S16；计算 E3〕

JEV 的合适角色是低延迟候选选择。 本地 EmbodiedJev 实现以文本状态和候选问题调用 Jev API，再由独立执行器动作；EmbodiedJev 项目 libero_v2 的执行器仍是数值伺服。Astra/JEV + VLA 是可验证的集成方向，当前没有该组合在 RPent 上的受控收益。〔E1/E3，S12、J1〕

建议的推进顺序

优先级	工作	验收结果
P0	补齐 MT low think 元数据与统一计时	确认单次延迟改善，同时检查成功率、轮数与全部 attempt 成本
P1	复合技能、进展检查和事件触发调用	减少大模型往返与失败恢复，保持成功判据
P2	固定候选的 JEV 选择器消融	隔离选择器增益，计入视觉候选生成和回退成本
P3	Astra/JEV + VLA 异频执行与 NPU profile	检验闭环成功、观测新鲜度和动作 deadline

1 实验范围与统一评价口径

本次汇总按实验协议分别呈现。任务、模型接入方式、thinking 档位、动作接口与成功谓词不同的实验，不合并为一个模型排行榜。下列数字描述各自报告中的有效样本，计划样本不计为完成量。〔E3〕

证据口径：E1 源码行号实证；E2 配置实证；E3 报告记载或推断；E4 未复核转述。本文引用已有实验报告的结果统一标 E3，不将历史报告里的实测标签直接升级为本次原始证据复核。

实验	已完成范围	主要用途与边界
GPT-as-Policy LIBERO v2	3 任务 × 3 路线 = 9 回合	Direct / Student / Hybrid；每格仅 1 条轨迹
bowl 原四模型	Astra 5；其余各 20	原四批共 65 条有效轨迹，接入与并发不同
bowl 9/23 补测	4 组 × 5 seed = 20 回合	Astra medium、Sol medium/ultra、Luna max 分别统计
RPent 正式评测	2 模型 × 3 套件 × 20 = 120 集	每任务 seed0/1；最终入账 attempt 集合
RPent 深度计时	2 场景 × 2 模型 × 2 seed = 8 集	独立补测，不并入 120 集
DeepSeek 两场景	原始 8 集与流式 8 集分开	流式 medium/none 各 4 集，t0 成功、t9 未完成
DeepSeek 专项	v5 15 轮；Files API 局 11 轮	两场独立轨迹；另有审计新增 15 请求主例
MT 最新 low think	4.6s 降至 1.4s	E4 新反馈，样本量与实验配置待归档

性能指标的边界

任务层同时报告成功率、每集成功时间、失败类型及全部尝试消耗。**决策层**区分逻辑决策、实际模型请求、传输重试和带 usage 的计量响应。**执行层**分别记录 VLA handler、动作原语、仿真与观测。串行段可按区间并集记账，父子 span 不重复相加。〔E3，S1、S6–S8〕

TTFT 是客户端首非空输出等待，包含上传、排队、服务计算和传输。可见 reasoning 窗口只反映客户端可见事件。按 token 比例拆出的 thinking/decode 是估算，均不能替代服务端 prefill 或完整 hidden thinking 时钟。〔E3，S6、S8〕

来源 S1–S11、S16。bowl 原四批和 9/23 补测分别保留；正式成功谓词与人工稳定放置审核不互相替代。

2 GPT as Policy 三任务与三路线实验

LIBERO v2 使用 Astra/medium，高层 Direct 输出末端目标，Student 使用 π0.5，Hybrid 由 π 提候选再交 GPT 审核。九回合共有 610 轮决策、3008 控制步、428 轮调用 GPT。每格仅 init 0，实验含并发，不属于隔离吞吐基准。〔E3，S1〕

任务	路线	结果	决策轮	整轮均值 s	episode s
两罐入篮	Direct	成功	97	14.41	1428.97
两罐入篮	Student	成功	52	4.20	248.71
两罐入篮	Hybrid	成功	51	18.82	991.09
微波炉	Direct	失败	105	17.36	1848.50
微波炉	Student	成功	70	3.41	262.34
微波炉	Hybrid	成功	51	19.65	1026.64
底层抽屉	Direct	失败	64	19.11	1254.40
底层抽屉	Student	失败	60	4.42	296.02
底层抽屉	Hybrid	失败	60	22.43	1377.62

实验能够支持的结论

两罐任务中，GPT 请求均值为 Direct 10.82s、Hybrid 14.37s，约占对应整轮时间的 75.1% 和 76.4%。Hybrid 的 π 推理含同步均值只有 0.53s。Student 的 4.20s 整轮中，渲染读回均值 2.77s，约占 66%。因此大模型往返和仿真观测成本比 π 单次计算更突出。〔E3，S1〕

成功的罐子与微波炉 Hybrid 各 51 轮全放行 Student；底层抽屉 13 次接管仍失败。可以说本次 Direct 成功 1/3、Student 与 Hybrid 各 2/3，但这只是跨任务九条轨迹的描述。π 随机状态未配对，微波炉 Hybrid 又来自补跑，轮数差异不能直接归因 GPT 纠错。〔E3，S1〕

本批支持后续测试按需审核与异常触发：正常动作块可由 VLA 连续执行，阶段结束或出现无进展再请求高层。是否提高成功率、减少轮数仍需消融。〔E3，设计〕

整轮均值对应决策循环；episode 边界包含额外初始化等成本，二者不可直接相乘代替。原计划与 RoboTwin 选型为 S2、S9，未计入已跑结果。

3 bowl 多模型对照与能力瓶颈

bowl 任务是 Panda 单臂将红块放入蓝碗。每条轨迹最多 20 次 LLM 调用及 900 控制步，等待决策时物理暂停。模型需要依据三视角图像与机器人状态闭环操作。以下为 9/23 同 seed2005–2009 的串行补测。〔E3，S3、S4〕

模型与档位	自动入碗	平均决策轮	平均墙钟 s
Astra medium	5/5	16.0	336.11
Sol medium	2/5	18.2	547.09
Sol ultra	3/5	17.6	600.63
Luna max	0/5	19.6	1969.76

自动入碗成功的 Astra/Sol 轨迹在报告中仍标注稳定放置的 stage3–4 边界：录像接近首次着地即结束，不能统一改写成稳定放置已确认。Sol medium 与 ultra 仅各 5 条；ultra 新成功的 seed 与 medium 独有成功的 seed 并存，不构成逐 seed 的单向改善。〔E3，S3〕

原四模型批次的定位

原四批自动入碗为 Astra 5/5、GLM 0/20、DeepSeek 1/20、Qwen 4/20。Astra 只有 5 条有效，不能写 20/20。原四批存在供应商、worker、并发与实际档位差异；Qwen 实际为 xhigh，GLM/DeepSeek 后端档位未暴露。耗时差反映模型与接入链路的共同作用。〔E3，S3〕

失败集中在感知与执行闭环

原三家对照中 48/60 停在 stage0–1，包含定位不收敛、抓持状态误判、动作跟随不足和预算耗尽。工具的步数与夹爪参数会改变运动结果，目标跟随残差不能叫视觉定位误差。仅缩短 thinking 可能减少等待，也可能增加错误动作和后续轮数。〔E3，S3〕

技术含义是将空间状态、抓持确认与局部执行放入可验证的反馈回路，再决定何时需要高层推理。bowl 结果支持研究这个方向，不提供真机双臂泛化或所有模型能力排名。〔E3〕

S3 为 v1.2（2026-09-23），文件名仍含 9/16。S4 为 v1.1，已更正原先误派 Astra 为真实 Astra 身份；模型展示标签不决定实际模型。

4 RPent 120 集正式结果与时间账本

Astra、Sol 均使用 medium，各 60 集，三套件各 20 集；120 个计划身份全部审定，成功 99 集、失败 21 集。成功按冻结环境 terminated 谓词判定。〔E3，S5〕

套件	Astra 成功	Sol 成功	Astra 均值 s	Sol 均值 s
Spatial Task	19/20	17/20	787.4	1248.6
Spatial Swap	20/20	20/20	586.9	943.7
Long Swap	11/20	12/20	973.7	1630.1
总计	50/60	49/60	13.04h 累计	21.24h 累计

Astra 总计多成功 1 集，Long Swap 则 Sol 多 1 集。样本不足以宣布普遍能力胜负。耗时包含失败与会话内连接等待；Sol 有一条 5348.4s 的已审定中断等待轨迹。累计时间不等于双线并行实验的日历时长。〔E3，S5〕

互斥时间桶	累计 s	占 episode	可解释范围
非 π 动作原语	45327.6	36.7%	控制、step、步内观测等
π0.5 动作原语	9367.1	7.6%	前向、chunk 执行与往返
工具附加	12429.8	10.1%	工具外围、采集与协议混合
SDK 非工具时段	53394.0	43.3%	请求、输出、网络、排队及重试
SDK 外壳	2889.9	2.3%	episode 内启动收尾等

五桶合计 123408.4s，约 34.28h。单独 VLA 加载 5.78h 另计。动作两桶共 44.3%，SDK 非工具 43.3%。优化优先级应同时覆盖动作重复和高层等待。即便固定轨迹下将 π 动作整桶清零，总体上限也约 1.082 倍，纯网络前向加速收益更小。〔E3，S6，按原始桶值计算〕

5014 是去重后带用量的计量响应，不等于全部真实请求。上述桶已包含内部子阶段，不再叠加 sim/render/π/SAM。

5 独立深度计时揭示执行侧边界

Astra/Sol 两场景深度补测共 8 集，t0 两罐入篮 3/4 成功，t9 微波炉 0/4 成功，合计 3/8。episode 累计 10965.30s。它提供本地细阶段计时，但不是 120 集的逐项补齐，也不代表两个任务以外的平均表现。〔E3，S7〕

观察量	8 集累计	同批 episode 占比	解释
原语窗内渲染	4391.18s	40.05%	inclusive 子阶段
物理 step1+step2	121.48s	1.11%	不含所有控制和观测
π handler	198.65s	1.81%	371 次，含其内部阶段
完整 π 动作	1110.09s	10.12%	包含动作块执行等开销
SDK 非工具	4187.54s	38.19%	仍不能等同纯 thinking

各行存在包含关系，不能相加为总耗时。π handler 只是完整 π 动作的一部分。固定轨迹、无额外开销且 handler 完全在关键路径的理想条件下，handler 加速一倍最多节省约 0.91%的整批 episode 时间。这是预算上限，不是已实现加速。〔E3，计算〕

后续以决策与恢复为主要优化对象

深度计时报告已将渲染从后续优化目标中排除。扣除已测原语窗渲染后的辅助量为 6574.12s，仍不等于真机时间。若这一辅助量需下降 10%，需节省约 657.41s；全部从 SDK 非工具时段取得时，该项需下降约 15.70%。〔E3，S7〕

长恢复段常同时增加动作、感知和下一轮请求。应先设计抓持确认、位移进展检查、有限重试与失败分类，避免在错误状态下重复同一动作。候选最短动作计划和“每集少若干轮”只是设计目标，不能当作已证明可删除的调用。〔E3，S7〕

将仿真渲染排除后，真机仍有相机采集、控制器周期、网络与安全检查。不能用 episode 减渲染直接承诺真实机器人速度。〔E3〕

8 集记录 448 次逻辑轮次/完整响应和 473 次传输尝试，额外尝试并不全可避免。另有 2 个 SAM OOM attempt 排除，其 3205.20s 已发生 episode 成本仍属复现成本。正式 8 集中仅 4 个 SAM 调用可匹配 client/server，共享 handler 活动不能全部归入本批。〔E3，S7〕

来源 S7。云端 prefill 与完整 hidden thinking 未独立暴露；请求区间可跨工具执行。跨设备单调时钟不得直接相减。

6 DeepSeek 思考开关的已有证据

两场景审计 v1.5 的流式 8 集比较 medium 与 none，每档 4 集。两档 t0/seed0、seed1 均成功，t9 均未完成。medium 的两个 t9 有输出预算异常退出，none 没有进程异常。两档成功率同为 2/4，不构成非劣性证明。〔E3，S8〕

共同成功 t0	medium	none	变化
episode 累计	2326.7s	1848.2s	下降 20.6%
逻辑决策轮	63	57	减少 6 轮
LLM 累计	1238.435s	715.819s	减少 522.616s
TTFT 累计	776.094s	607.904s	减少 168.190s
reasoning tokens	45618	0	输出计量变化

分 seed 看，t0/seed0 耗时下降 30.4%，seed1 仅下降 2.9%。关闭思考改变了输出、上下文、轮数与执行轨迹，不能将整集 478.5s 收益全部归给 thinking 计算。两档 prompt 也并非逐字相同。〔E3，S8〕

瓶颈随上下文与轨迹变化

流式成功 4 集共 120 次逻辑请求，LLM 累计 1954.3s，其中 TTFT 约 1384.0s，占 70.8%。另一条新增 object_swap t2/seed0 主例为 15 请求、episode205.3s，LLM110.534s，其中首输出后 88.796s，占 80.3%。两组分别偏向首输出前等待和首输出后输出，不应套用统一瓶颈占比。〔E3，S8〕

流式 8 集的逻辑请求与传输尝试需要分开，178 次传输尝试中，TTFT 与 TPOT 各有 177 条有效记录。medium 共同成功 t0 两集按输出 token 比例拆分的 thinking352.550s 和 decode97.379s 属于估算；报告中“prefill 代理”实质取 TTFT，包含网络及服务等待。〔E3，S8〕

下一轮可对正常阶段尝试 low，对异常恢复保留更高档位，并记录回退率。是否优于 none 或全程 medium，必须在固定任务和配对 seed 中重新验证。〔E3，设计〕

S8 为本次优先采用的 DeepSeek 审计口径。原始 8 集、流式 8 集、新增 15 请求主例均单独保留，不能用不同批次总时长宣称提速。

7 MT 最新 low think 结果与收益边界

MT 最新实验反馈：开启 low think 后，think 耗时由 4.6s 降至 1.4s。 该结果由用户于 2026 年 10 月 14 日补充，未包含在所列历史报告中。本文将其作为新的阶段性实验反馈保留，证据级别 E4；历史报告未收录不表示该结果错误。〔E4，S16〕

指标	计算	结论
阶段耗时差	4.6 − 1.4	该阶段指标减少 3.2s
阶段耗时降幅	3.2 ÷ 4.6	69.6%
阶段加速比	4.6 ÷ 1.4	约 3.29 倍

单次耗时与轮数的联合模型

串行近似下，T = N × (q + h + d) + A + O。其中 N 为实际高层请求数，q 为 think 之外的首输出前等待与处理，h 为 think 阶段，d 为其余输出，A 为动作与工具独占时间，O 为外围开销。若阶段可重叠，应改用关键路径。〔E3，模型〕

如果 MT 的 4.6s 与 1.4s 是同口径的每请求均值，且 N 与其他成本保持不变，则 T_low = T_base − 3.2N。thinking 占原始端到端时间的比例为 f 时，总体加速比为 1 / (1 − 0.69565f)。下表仅为预算情景，不属于新实验成绩。〔E3，基于 E4 条件计算〕

thinking 原占比 f	端到端时间降幅	总体加速比
10%	约 7.0%	1.075 倍
30%	约 20.9%	1.264 倍
50%	约 34.8%	1.533 倍

若 low think 增加误判、重复抓取或恢复次数，N 与 A 可能增长并抵消收益。因而应联合报告 think p50/p95、请求 p50/p95、任务成功率、轮数、成功集耗时和全部 attempt 成本。不得将 69.6%阶段降幅写成 69.6%整机提速。〔E3〕

待归档字段：模型及版本、baseline/low 参数、任务与 seed、重复次数、缓存/并发、think 时钟起止、均值或分位数、成功判据与完整请求耗时。MT low 与 S8 medium/none 为独立证据。

8 DeepSeek 专项实验与计时口径修正

真实 TTFT v5 与 Files API 优化局是两场独立实验。两者的路线、轮数、缓存和计时实现不同，不能按文件名称将后者视为前者新版，也不能把 182.5s 与 153.1s 之差归为某一个优化开关的收益。〔E3，S10、S11〕

报告	实验范围	可以保留的观察	需要限制的推断
TTFT v5	10/11，t2/s0，15 轮，182.5s	流式代理；TTFT 中位数 1.07s；文件引用替换内嵌图像	客户端子区间不能叫纯服务端 prefill
Files API 局	10/10，t2/s0，11 轮，153.1s	文件引用与输入载荷策略的独立尝试	部分阶段为 token 估算；纯 prefill 与排队未独立测量
后续审计主例	另一个 15 请求，205.3s	LLM110.534s，首输出后占 80.3%	不与 v5 的 15 轮/182.5s 合并

可取的优化方向

Files API 及内容哈希复用有望减少重复上传。v5 展示的请求体从约 4.6MB 转为约 0.2MB，但新增图仍有上传成本，端到端收益需同请求重放验证。文件引用是否保留服务端图像计算或缓存命中，必须依据该服务实际接口与观测确认。〔E3，S10〕

v5 记录 π0.5 独立调用约 384ms/chunk，样本 10 次，5 步动作摊销约 76.8ms/action。若执行窗口为 5 步 ×50ms=250ms，384ms 延迟已大于窗口，局部控制实时性仍值得优化。此处的直接调用测量与深度补测 handler 插桩条件不同，不合并作同一设备横向速度比较。〔E3，S10，计算〕

不直接沿用的旧结论

旧报告将客户端等待称为“DS 服务端 prefill”，或将超出孤立基线的时间全部归为排队，证据不足。由 reasoning tokens 乘常数得到的时间仍是估算。Files API 局中“11 轮降 8 轮”“153s 降 92s”等是条件推演，不是实跑结论。〔E3，S8、S10、S11〕

后续保留每次发送、响应头、首非空 reasoning/正文/工具参数、末事件的单调时钟。若服务不提供计算 span，报告客户端区间及其不确定性，不反推纯 prefill 或 hidden thinking。〔E3，设计〕

9 JEV 决策模型的定位与集成路径

本地 EmbodiedJev 参考实现把 Jev 作为候选选择 API 使用：文本 state 与 questions 送入 TypeSafe System One 接口，返回 choice 和 probabilities。仓库没有可直接部署到 NPU 的 Jev 开源 checkpoint，也未公开可审查的服务端网络参数。官方资料称其采用 RLCD；本报告只按接口与公开文档界定能力。〔E1/E3，S12、J1〕

与 RPent 的主要差别

环节	EmbodiedJev 当前参考链	RPent 与建议集成
状态与候选	文本结构化状态；EmbodiedJev libero_v2 由 Astra 处理视觉并生成候选	沿用必要视觉、空间状态和任务上下文
高层决策	Jev 在有限候选中选择，可同 state 提交多题	Jev 选择技能或恢复分支，复杂情况回 Astra
执行	Panda 工作台/数值伺服等独立执行器	π0.5 动作块与已验收脚本原语
验证	通过环境/执行反馈推进状态	保持冻结成功谓词，加入可观测进展检查

EmbodiedJev 项目 libero_v2 链的 Astra 视觉候选、Jev 或 GPT 选择器、数值伺服链并未接入学习型 VLA。选择器 API 快不等于视觉闭环快；如果每轮仍需 Astra 生成候选，则 Jev 新增请求可能抵消收益。〔E1/E3，S12〕

先隔离候选与选择器的作用

第一步构造固定的技能候选和相同结构化状态，比较规则、Astra、Jev 三个选择器。候选中加入继续、重新观察、恢复和停止；probabilities 只作待校准信号，不能当作真实成功概率。第二步才开放动态视觉候选，并把 Astra 调用率和状态更新成本计入。〔E3，设计〕

JEV 的潜在收益来自降低选项决策成本与减少不必要的大模型调用。它也可能通过进展感知选择减少重复动作，但该效果取决于候选质量和反馈，尚未在 RPent 证实。候选覆盖不足、状态陈旧和分布外对象会触发回退。〔E3，设计〕

源码与固定提交定位见 S12 及 J1；2026-10-13 本机规则基线 9/9 属于该参考项目测试，不是 Jev 或 RPent 的新机器人成功率。

10 Astra JEV 与 VLA 的分层执行方案

建议比较两种可部署的职责分工。基础方案由 Astra 做低频任务规划与异常恢复，VLA 执行局部动作。扩展方案在中间加入 Jev，针对稳定状态从有限技能或恢复候选中选择。高层调用由阶段事件触发，局部观测和安全检查持续运行。〔E3，设计〕

组件	输入与输出	触发条件
Astra	任务、关键视觉状态、失败摘要；输出子目标或更新技能候选	任务开始、新对象/新阶段、低置信或连续无进展
Jev 选择器	紧凑状态+有限候选；输出技能 ID/分支	阶段边界或局部状态发生有效变化
VLA 与脚本原语	当前观测+局部 instruction；输出动作 chunk 或原语执行	执行技能时按控制窗口连续调度
验证器	抓持、目标位移、状态变化、终止谓词	每 chunk/关键动作后，异常时停止或回退

与每轮审核的对比

GPT-as-Policy 当前 Hybrid 在每轮候选后等待 GPT 审核，成功轨迹没有展示纠错收益。事件触发方案只在阶段边界或异常时请求高层，能够在设计上减少请求数；必须计入复合技能内部感知与验证成本，不能靠省略反馈换速度。〔E3，S1 及设计〕

时间与状态一致性

使用请求 ID、技能 ID、观测时间戳和动作版本关联各层。VLA 继续执行时，高层返回的决策可能基于过时图像；结果接纳前检查观测新鲜度与技能版本。异步策略需要允许安全取消或在 chunk 边界切换，不直接将旧动作序列拼接到新状态。〔E3，设计〕

chunk 大小同时影响调用频率、动作前视范围和反馈频率。增大 chunk 可摊销推理，却可能延长错误动作和恢复时间。独立记录模型延迟、动作窗口、buffer 欠载、观测年龄和重规划间隔，才能判断是否满足实时闭环。〔E3，设计〕

方案是下一阶段实验设计，未宣称已完成 Astra/Jev+VLA 融合、NPU 部署或真机验证。

11 关键技术趋势与异腾优化边界

趋势一 高层推理与低层动作采用不同频率

已有实验显示逐动作调用云端大模型的等待成本显著，而局部操作可以由 VLA 或脚本持续执行。公开的分层/异步 VLA 工作也研究将语义推理与快速动作分离。对本项目的判断是：先建立可靠的技能边界、事件触发和恢复逻辑，再决定大模型调用频率。〔E3，S1、S12、S13 及官方资料〕

趋势二 推理预算按任务阶段分配

MT low think 反馈与 DeepSeek medium/none 实验均支持进一步研究推理预算，但证据范围不同。简单、已见过的选择可低档位运行；新场景、歧义状态和恢复步骤可能需要更多推理。应优化成功率约束下的总请求成本，而不是单独最小化 thinking tokens。〔E3/E4，S8、S16〕

趋势三 状态压缩与缓存必须保持任务信息

长历史、重复指南与多视角图像增加输入成本。可以保留稳定前缀、对象状态、已验证子目标和失败摘要，同时保留必要原图用于再判断。压缩比例不等于延迟下降比例，缓存命中也不证明 prefill 已无成本。固定请求重放和闭环回归应分别验证。〔E3，S6、S8、S13〕

趋势四 局部实时性与整集瓶颈需要分别优化

即使 π 前向占整集时间较小，单 chunk 超过动作窗口仍会影响连续控制。NPU 优化应以实际 profile 区分矩阵计算、attention/KV 读取、Vector 算子、访存、搬运和 launch 开销。云端模型的队列与内核不能由本机直接优化。〔E3，S7、S10、S14〕

910B3 首批 32 次方案是 8 个固定请求×4 次的计划，模型多图部署与推理尚待执行。它适合建立本地 VLM 推理分阶段基线，不能在本报告中写成已验证的 NPU 吞吐、硬件瓶颈或性能收益。〔E3，S15〕

趋势为工程判断，不是行业统一性能结论。官方资料与源码定位列于附录；没有服务端 trace 时，不以 TOPS、token 数或客户端等待直接确定芯片计算瓶颈。

12 最小受控实验与验收矩阵

实验分两层进行：固定请求重放用于隔离单次推理变化，闭环任务用于检验轮数、成功率与恢复成本。先在 t0/t9 做小样本探针，再扩展到原 120 身份集合。保留环境、模型版本、任务初态、工具、成功判据和排除协议。〔E3，建议方案〕

组别	只改变的因素	必须保持或记录	检验问题
A0	当前 Astra+原语/VLA 基线	原冻结协议	复现对照
A1	thinking 档位	固定请求及闭环配对	单次变快是否增加轮数
A2	输出/历史压缩	必要图像、状态与语义信息	传输与输出是否实际下降
A3	复合技能及事件触发	同一 VLA、终止与回退谓词	减少高层请求的收益
A4	规则/Astra/Jev 选择器	相同状态与候选集	隔离选择器贡献
A5	动态候选与 Jev 回退	计入 Astra 生成候选成本	真实组合是否值得加入
A6	同步/异步 chunk 调度	同权重与动作范围	实时性和陈旧动作风险

联合指标与通过条件

主要指标是冻结成功率、共同成功轨迹耗时、所有 attempt 累计成本、N_request、N_retry 和无进展恢复次数。辅助指标包括 TTFT、可见输出窗口、tokens/cache、π handler p50/p95、动作步数、加载时间及观测年龄。失败更快不算任务加速。〔E3〕

先由负责人预注册可接受的成功率下降幅度及时间收益目标。若采用 5 个百分点作为示例非劣性边界，应基于配对成功差的置信区间检验，并根据功效估计补样本。每格 1 例、两 seed 或每档 4 集都只能作探针，不能宣布统计等价。〔E3，建议〕

将模型成功、工具错误、输出预算失败、基础设施异常分别记账。共同成功子集可解释延迟差，但存在条件选择，应同时展示全部配对结果和总消耗。按任务/seed 聚合不确定性，不能把同一 episode 内的请求当成独立任务样本。〔E3〕

不使用上游不同任务/训练数据的成绩作为本项目验收门槛。RoboTwin 社区 π0.5 选型资料仅作路线参考，见 S9。

13 实施优先级与最终建议

阶段	交付内容	进入下一阶段的条件
阶段 0 证据对齐	MT low think 实验卡；统一请求/阶段/动作 span；基线复放	时钟和分母可复核，原始记录保留在受保护实验区
阶段 1 单次耗时	同模型 thinking 档位、输出简化、稳定前缀与图像复用消融	必要信息保留，成功率和轮数无不可接受退化
阶段 2 减少轮数	复合技能、进展检测、有限恢复、事件触发 Astra	同时减少大模型请求和无效动作，额外验证成本已计入
阶段 3 JEV 与 VLA	固定候选 selector 消融，再评估动态候选和异步 VLA	Jev 增益超过接入/候选生成成本，回退与实时性合格
阶段 4 芯片定向优化	固定负载 profile、热点 kernel、数据搬运与精度对照	热点在关键路径，端到端收益和数值/闭环回归均通过

对两个问题的完整回答

性能评估报告。 已完成三任务三路线、bowl 多模型、RPent120 集、独立 8 集深度计时与 DeepSeek 专项。结论是：复杂长程任务仍受能力与恢复策略限制，云端往返和动作执行共同构成大头。独立补测表明 π handler 占整集时间较小；仿真观测成本和真实机器人控制成本应分开讨论。〔E3，S1–S11〕

优化推理单次耗时乘轮次。 low think 优先影响单次成本；Jev 选择器与复合技能优先影响高层请求成本和频率；Astra/Jev + VLA 通过职责与频率分离争取减少高层等待。三者存在交互，收益不能直接相加。每次方案变更都应联合比较成功率、请求数、动作步数和全部 attempt 耗时。〔E3，S12–S16〕

近期最可执行的路线是先把 MT 的 3.2s 阶段节省落实到可复核实验卡，并测试是否维持决策质量；同时利用已有任务构建复合技能和进展反馈。随后在相同候选集上检验 Jev，最后再评估完整异步双脑及 NPU 定向优化。当前没有证据支持承诺某一组合的固定总加速倍数。〔E3，建议〕

文档为 v1.0 综合评估。实验结果、上游实现与后续设计均在各节明确标注；未开展新的远程仿真、模型训练或机器人实验。

附录 资料索引与版本

路径以工作区根或 embodied-ai 仓库根为基准。S1–S15 为既有文件，S16 为本次用户补充。报告采用来源标题、版本与章节定位，不复制原始会话、凭据或运行端点。

编号	资料与位置	本文用途
S1	GPT-as-Policy-repro/data/decision_v2_20260922/index.html 多任务逐轮决策实录 v1.9，9/29	§5–§8 及内嵌九回合汇总
S2	GPT-as-Policy-repro/2026-09-17-GPT-as-Policy 在 MuJoCo 与昇腾上的复现计划.md	计划与执行范围区分
S3	weeks/2026_0914-0920_GPT6Astra 评测复现/2026-09-16-bowl-eval-v1 四模型总结报告.html v1.2，实际更新 9/23	§2、§3、§5
S4	weeks/2026_0921-0927_同机仿真与云边验证/2026-09-23-GPT6-Sol-bowl 五次与 Astra 同 seed 对照.md v1.1	模型身份更正、配对结果
S5	weeks/2026_0928-1004_RPent 双脑对照与回馈/2026-10-01-RPent-Codex 双模型 120 集结果.md v1.0	正式身份、成功与耗时
S6	weeks/2026_1005-1011_RPent 推理性能分析/2026-10-08-RPent-120 集推理耗时与优化报告.html v2.0	互斥五桶、响应计数与归因边界
S7	weeks/2026_1005-1011_RPent 推理性能分析/deep-report/RPent-两场景深度计时报告.html	8 集计时及敏感性预算
S8	weeks/2026_1012-1018_RPent 多模型性能分析/ds-report/RPent-DeepSeek-两场景性能审计.html v1.5	medium/none、分段口径与新主例

本文 E3 表示本次按报告记载复核汇总，不否定源报告曾完成实测；E1 仅用于已查看的代码接口与实现事实。

附录 选型资料与新增证据

编号	资料与位置	用途与限制
S9	GPT-as-Policy-repro/2026-09-21-RoboTwin2.0 双臂测评集与 π0.5 微调权重调研报告.md	选型调研；不同训练数据/任务范围的数字不作代际收益
S10	rpent-repo/ds_flash_v5_report.html 真实 TTFT v5，2026-10-11	15 轮 182.5s 专项；保留客户端测量边界
S11	rpent-repo/files_api_report.html Files API 优化局，2026-10-10	11 轮 153.1s 独立实验；旧计时推断以 S8 审计限制
S12	weeks/2026_1012-1018_RPent 多模型性能分析/2026-10-13-EmbodiedJev 项目分析与 RPent 对比.md	Jev 接口、选择器和执行器分工
S13	同周/2026-10-13-VLM-VLA 双脑架构与推理优化调研.md	架构、异频调度与受控消融
S14	同周/2026-10-13-具身 VLM 推理的芯片加速单元与验证路径.md	计算单元与 profile 路径
S15	同周/2026-10-13-910B3 本地 VLM 首批 32 次推理基线执行方案.md	32 次固定请求实验计划，非已跑性能
S16	2026-10-14 用户补充：MT 的最新 low think 实验反馈，think 4.6s 降至 1.4s	E4；待附配置、样本量、阶段时钟与任务结果

源码与官方资料

J1 固定版本 FBddcz/embodied-jev@f08de2e4e20d6cd69fea9c57ac1062c3ef510f1e。policies.py 第 277–422 行：API 请求与返回；libero_supervisor.py 第 101–289 行：视觉候选、selector 与数值伺服；policies.py 第 509–534 行：本地 MiniCPM 候选 logits 路径。〔E1〕

J1 EmbodiedJev 固定源码与接口

J2 TypeSafe System One 与 Models 官方说明

W1 Hi Robot 论文 2025

W2 Figure Helix 官方技术说明 2025

W3 Real Time Execution of Action Chunking Flow Policies 2025

官方资料访问日 2026-10-14。J2 与 W1–W3 均为 E3 文档/论文证据，支持接口和技术方向判断，不构成本项目性能复现。