具身智能推理性能评估

实验成果与耗时诊断

质量基本不降，是比较所有优化路线的前提

已有证据	本次汇报重点
RPent 120 集，成功 99/120	长程任务与高层等待仍有优化空间
独立深测 8 集、 DeepSeek 多组专项	分别定位本地阶段、请求窗口与长尾
候选优化尚未选定	同质量下比较单次等待、调用轮数与本地实时性

报告数字为 E3 重述，源码接口为 E1 ， MT 最新反馈为 E4 待补证。

指标与计时边界

同步近似： episode ＝初始化＋ N× 平均完整请求等待＋执行与恢复

指标	本次含义	不可混用的边界
episode 墙钟	整集任务的外层时间	失败早停、加载、配对屏障各自注明
完整请求等待	发送／准备起点至完整结果可用	首次响应不等于可执行动作已完成
TTFT 与可见 thinking	客户端首事件、首输出、首正文窗口	不是纯 prefill 或完整 hidden thinking
工具与本地 span	π handler 、 render 、 physics 等	父子嵌套项不能再次相加

先比较成功与任务质量，再比较延迟分布、完整请求和整集关键路径。

TPOT 须写明分母。计量响应、逻辑请求与传输 attempt 分开计数。

N 按逻辑请求计数，平均完整等待包含全部 retry ／重连。异步按关键路径统计。〔E3〕

实验总览：各集合回答不同问题

实验集合	规模	可回答的问题
GPT-as-Policy	3 任务 ×3 路线＝ 9 回合	接口、整轮与云端监督开销
bowl 同 seed	4 配置 ×5seed ＝ 20 回合	小样本任务能力与 effort 敏感性
RPent 历史／独立深测	120 集／ 8 集	成功结构、互斥总账与本地细分
DeepSeek 档位对照	medium ／ none 各 4 集	共同成功轨迹的质量与成本变化
DeepSeek 三个单局	v5 ／ Files API ／后续 phase	请求窗口、 payload 与输出长尾

多路线实验检验单轮成本与轮数，正式评测和插桩深测补充不同计时证据。

本次审查既有报告，没有新增远程机器人或 NPU 性能实跑。

跨环境、轨迹、成功谓词与计时实现分别解释，不能合并成模型排行榜。〔E3〕

GPT-as-Policy： 罐子三路线

路线	决策轮	平均整轮 / s	episode / s
Direct	97	14.41	1428.97
Student （ π0.5 ）	52	4.20	248.71
Hybrid	51	18.82	991.09

请求均值	request/s	TTFT/s	可见 decode/s	TPOT 估算 ms/token
Direct	10.819	7.340	3.155	25.55
Hybrid	14.374	4.455	9.618	29.06

本条 Hybrid 轮数更少，但每轮更慢。其可见输出较多，监督增量质量仍需验证。

Student π+sync ／ render 为 0.545 ／ 2.774 s， Hybrid 为 0.530 ／ 2.938 s 。

每路线仅 1 条成功轨迹。 Hybrid 全 51 轮放行 Student， π 随机状态未配对。 request 包含 TTFT/decode 。〔 E3 〕

bowl：同 seed 的质量与整集耗时

模型／ effort	自动入碗	平均决策轮	平均墙钟 / s
Astra medium	5/5	16.0	336.11
Sol medium	2/5	18.2	547.09
Sol ultra	3/5	17.6	600.63
Luna max	0/5	19.6	1969.76

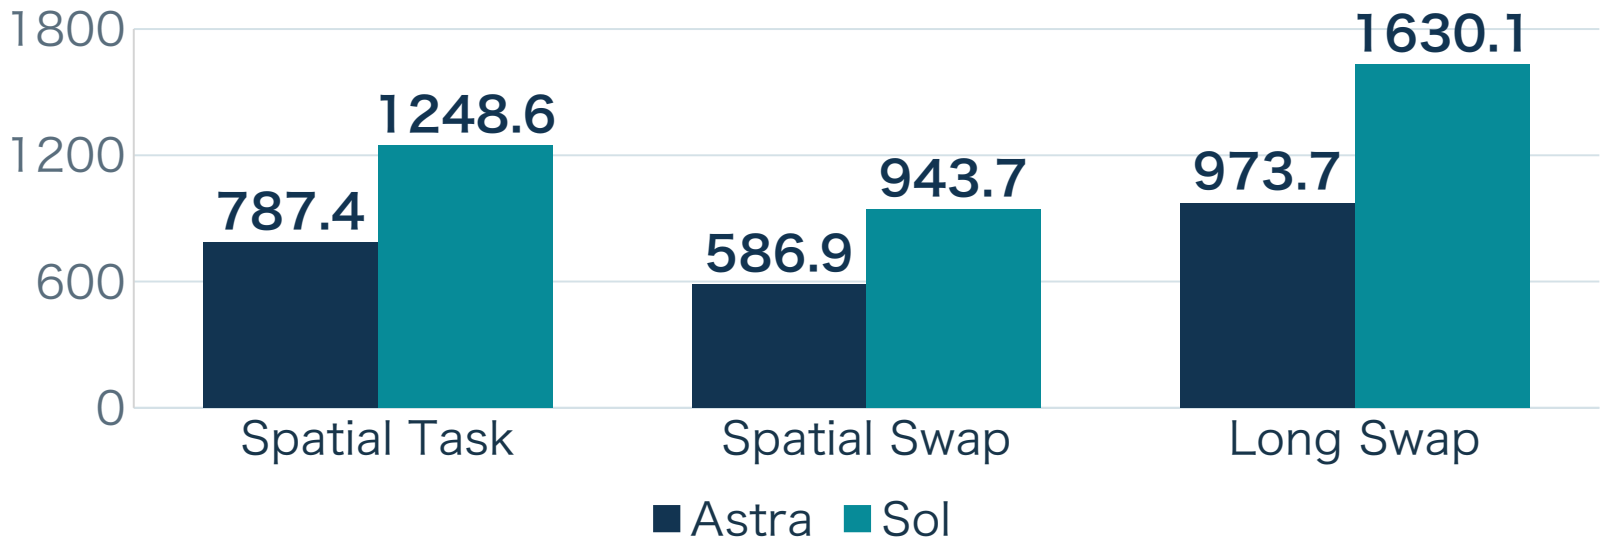
9/16 代理等待	Astra	GLM	DeepSeek	Qwen
非纯 LLM / s	27.2	≈117*	135	≈110*

同 seed 没有 LLM 分段。更高 effort 未带来逐 seed 一致改善，质量仍需闭环确认。

主表 n = 5，入碗未等同稳定放置。下表 9/16 等待含读图 / 工具往返 / 调度，* 推算，三家子集未明。〔E3〕

RPent 120 集：整集耗时按套件比较

episode 均值 / s，质量与完成结果保持为比较约束



p50 / s	Spatial Task	Spatial Swap	Long Swap
Astra	676.8	560.0	919.5
Sol	811.6	828.9	1332.8

质量为约束

Astra 成功 50/60
Sol 成功 49/60
逐套件结果见页脚。

连接长尾需保留

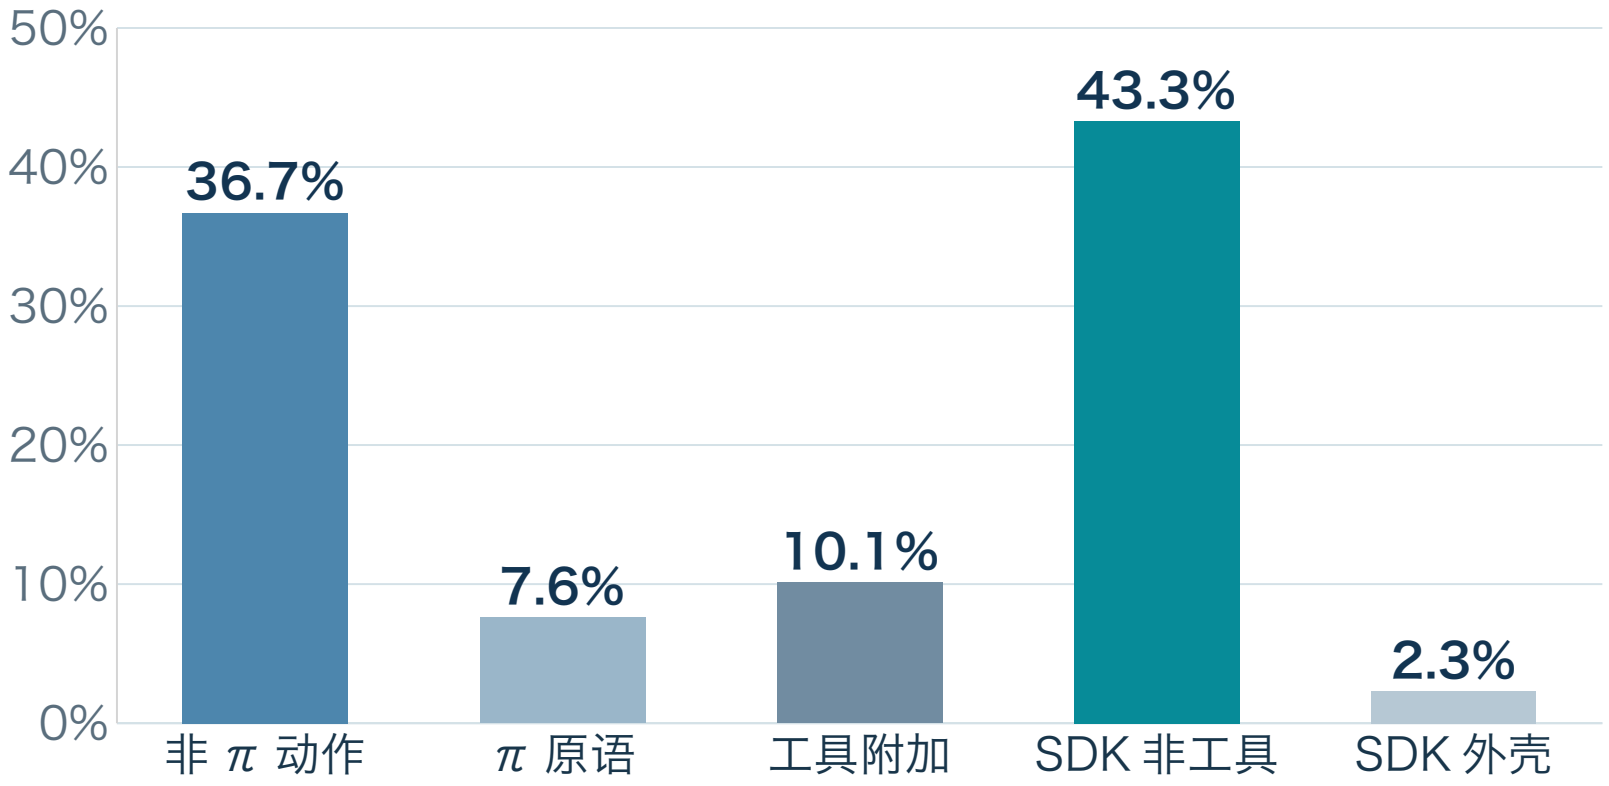
Sol Long 一轨 5348.4 s
含连接中断。
均值受到长尾影响。

成本不等于算力

轨迹、轮次与连接
共同影响整集耗时。
不作纯算力归因。

每模型每套件 n = 20 。 A/S 成功： Task 19/17 ， Swap 20/20 ， Long 11/12 。含失败与连接等待。〔E3〕

RPent 120 集：高层等待与动作并重



动作两桶 44.3%

含策略、控制、仿真、渲染与通信。

SDK 非工具 43.3%

含请求、网络、重试与编排，需继续拆分。

总账先定位范围

五桶不足以计算纯 π 或纯 thinking 的加速比。

优化需要同时量化单次等待与调用数量，局部阶段缩短未必同比缩短整集。

分母 123408.4 s 。五桶互斥， VLA 加载 5.78 h 另计。 SDK 非工具不等于 thinking 。〔E3〕

独立 8 集：渲染与 π handler 细分

本地细分的分母 10965.30 s，与历史 120 集分开解释

已测阶段	累计 / s	占 episode	测量含义
原语窗内 render	4391.18	40.05%	仿真观测成本
physics step1+2	121.48	1.11%	不覆盖所有控制工作
π handler	198.65	1.81%	371 次，包含处理开销
其中 prefix / denoise	96.19 / 86.14	0.88% / 0.79%	属于 π handler 的子阶段

扣除已测 render 后 T* = 6574.12 s，仍不是真机耗时预测。

π handler 减半仅省 T* 的 1.51%，整集收益有限，但局部 deadline 仍需单独验收。

独立 8 集成功 3/8（t0 为 3/4，t9 为 0/4）。子阶段嵌套，不能加回 episode 。〔E3〕

独立 8 集：轮次、重试与恢复

样本	结果	episode/s	逻辑轮	attempt	π 块
t0 A/0	成功	1090.5	41	41	15
t0 S/0	成功	1153.1	47	53	28
t0 A/1	成功	1049.1	41	42	15
t0 S/1	失败	2176.5	77	83	116
t9 A/0	失败	1711.6	75	75	28
t9 S/0	失败	1409.8	65	71	100
t9 A/1	失败	1076.7	47	47	8
t9 S/1	失败	1298.0	55	61	61

请求量需独立计数

448 逻辑轮
473 次传输尝试
额外 25 次需分析原因。

恢复存在长尾

Sol t0/s1 为 77 轮
116 个 π 块。
次数不等于无进展。

可省部分需验证

两段恢复扣 render 后
152.01 s，占 T*2.31%。

候选切入点：阶段进展判断、有界恢复与事件触发，质量和完整关键路径一起验收。

逻辑轮次与 attempt 不同。恢复耗时中可含大量 render，不能全部当无损节省。〔E3〕

DeepSeek v5： 请求指标的均值与 p50

单局 15 轮 182.5 s， LLM 累计约 93.6 s（约 51.3%）

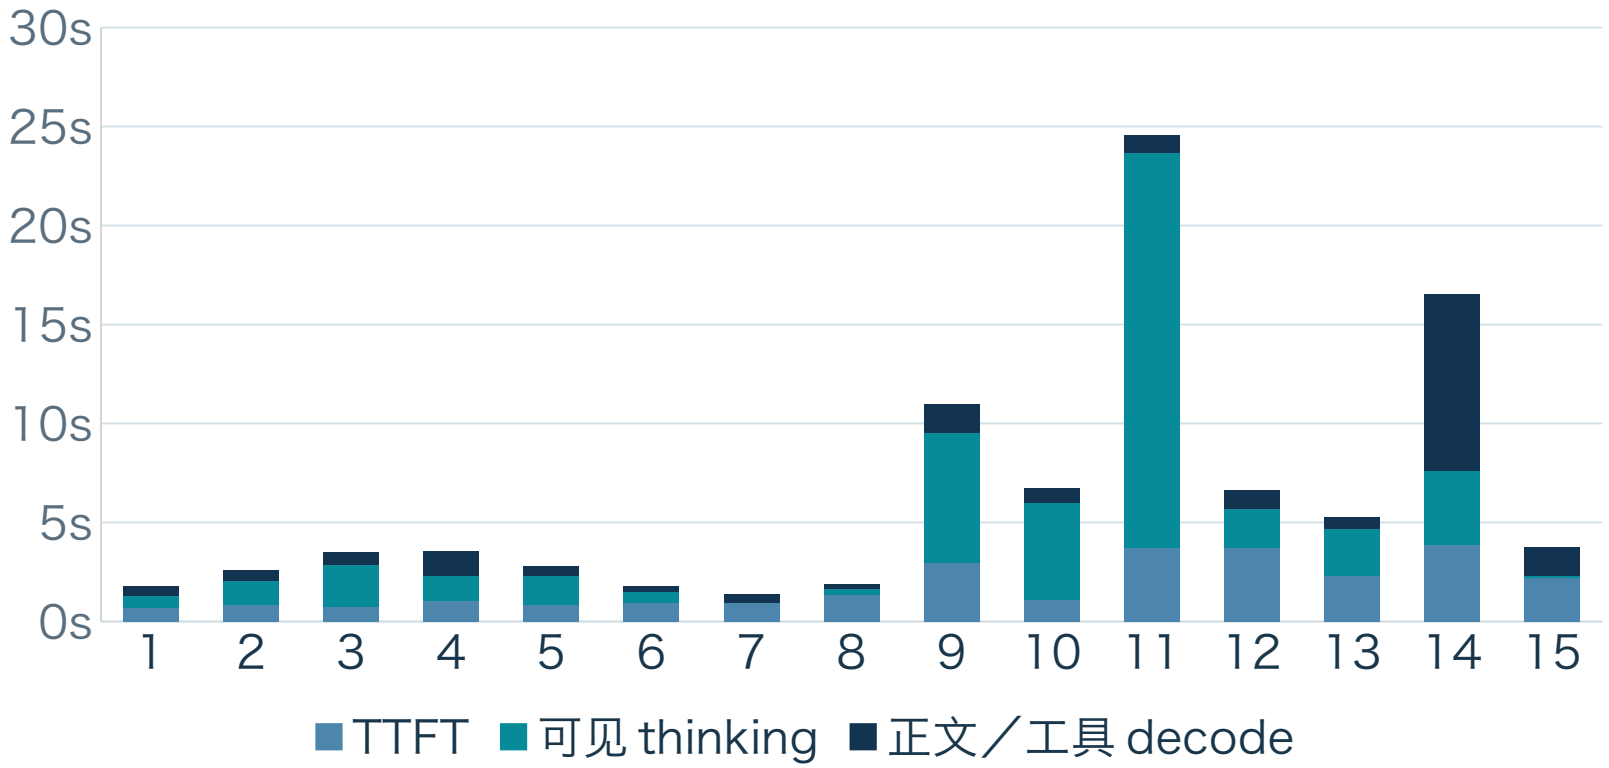
客户端指标	均值 / s	p50 / s	定义
TTFT	1.817	1.07	请求起点至首 SSE chunk
可见 thinking 窗口	3.143	1.46	首 chunk 至首正文 chunk
正文／工具 decode	1.280	0.65	首正文 chunk 至结束
完整 LLM 请求	6.24	3.50	完整请求窗口

均值高于中位数，长尾决定累计等待，不能只看“典型一轮”。

旧 v5 TPOT 约 4 ms，后续同局按 output−1 分母得 p50 为 3.621 ms，定义不同。

报告逐轮表重算，均值为约数。首 SSE 是否过滤空事件未确认，均为客户端窗口。〔E3〕

DeepSeek v5： 15 轮长尾来自不同窗口



第 11 轮： thinking

19.96 s ／总 24.5 s
reasoning 4491 tokens

第 14 轮： decode

8.94 s ／总 16.5 s
其他输出 2687 tokens

优化对象不同

思考预算、工具载荷和完整结果时间需分别验证。

182.5−93.6≈88.9 s 先称“工具及其他剩余时间”，不能直接归为纯工具或纯渲染。

15 轮含初始化读资料、写记录与 finish 。表内三窗口经舍入，分项合计可能略有差异。〔E3〕

DeepSeek： payload 、 cache 与 context 边界

观察对象	报告内证据	可解释范围
v5 请求 payload	15 次均值 3136.1 降为 185.7 KB 末轮 10118 降为 280 KB	请求体缩小，图片上传阶段仍需计入
上下文与缓存	输入 13,094 增至 84,686 tokens 缓存比例均值 88.5% ， p50 97%	跨请求输入重复历史，不能当新增输入
图像与 TTFT 探针	禁裁剪、末轮 13 图 另 3 次探针冷 1.45 ／热约 1.0 s	同时改变多项条件，仅支持该输入基线
服务端阶段	“DS 服务端”均值 0.46 ／ p50 0.44 s	客户端代理区间， prefill 与排队仍未拆分

缓存收益要同时记录命中条件、输入稳定性、上传成本与完整请求时间。

减少上下文或图像前，先确认对象识别、历史状态与任务质量保持。

v5 与 Files API 旧局是独立集合。 KB 沿用原报告单位，未确认 1000/1024 口径。〔E3〕

DeepSeek medium ／ none： 共同成功两 seed

共同成功 episode 合计 2326.7 降至 1848.2 s，下降 20.6%

配对初态	medium	none	耗时下降
t0 / seed0	1497.8 s / 37 轮	1043.1 s / 31 轮	30.4%
t0 / seed1	828.9 s / 26 轮	805.1 s / 26 轮	2.9%
两 seed 合计	2326.7 s / 63 轮	1848.2 s / 57 轮	20.6%

轮次同时 63 降至 57，无法把 20.6% 全部归为同轨迹 thinking 缩短。

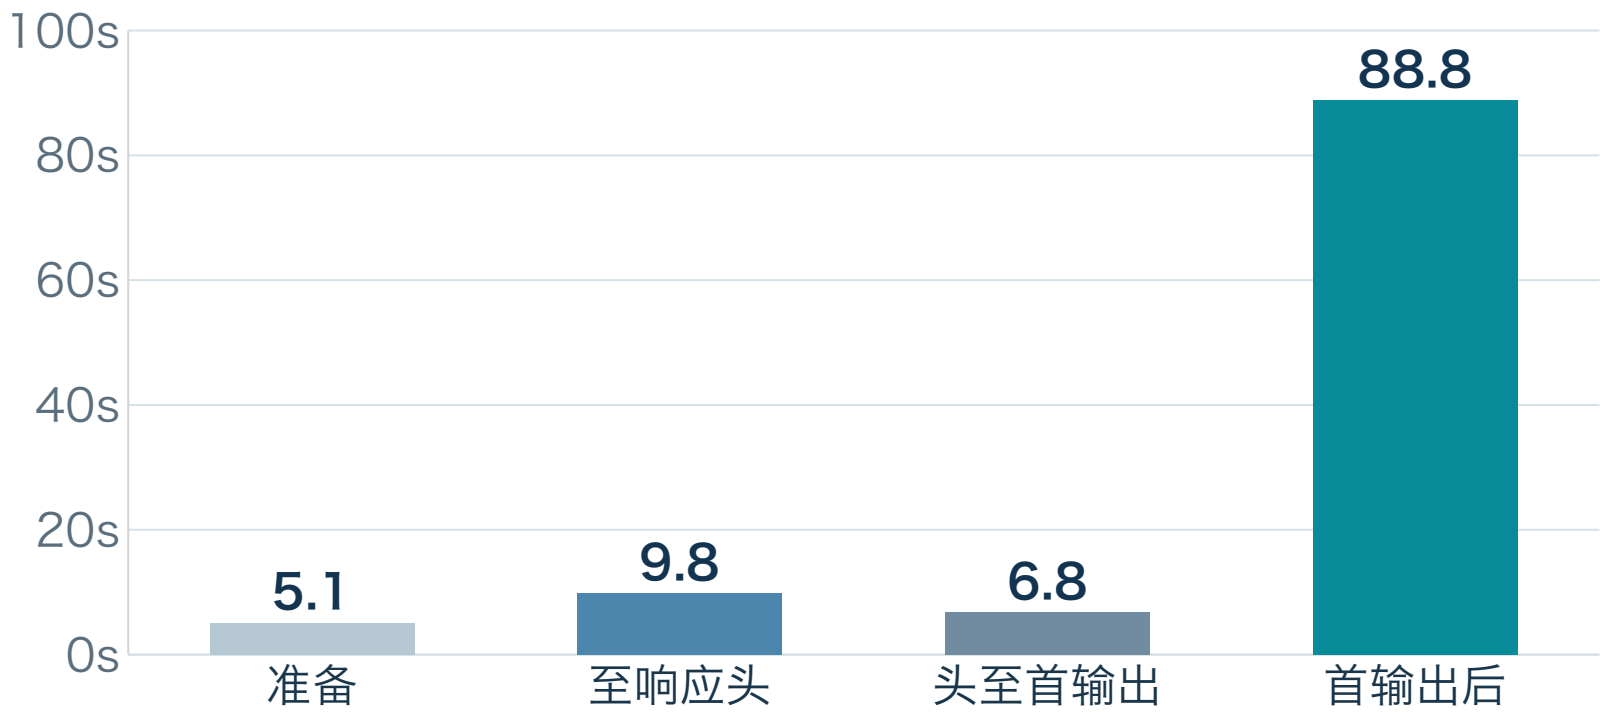
共同成功四集 TTFT 代理占 LLM 累计 70.8%，包含网络与等待。

medium 两成功集 thinking 估计 352.550 s 按 token 分摊，不能替代服务端阶段实测。

每档 2/4 成功， t9 均未完成。小样本、 system hash 不完全相同，不证明成功率等价。〔E3〕

DeepSeek 后续审计：首输出后占 80.3%

episode 205.3 s， LLM 110.534 s，首输出后 88.796 s



TTFT 占 19.7%

累计 21.739 s
p50 1.270 s

输出窗口更大

14 个可见 thinking 窗口
累计 68.663 s 。

优化预算随集合变

同样缩短 20% :
输出窗口约 17.76 s
TTFT 约 4.35 s 。

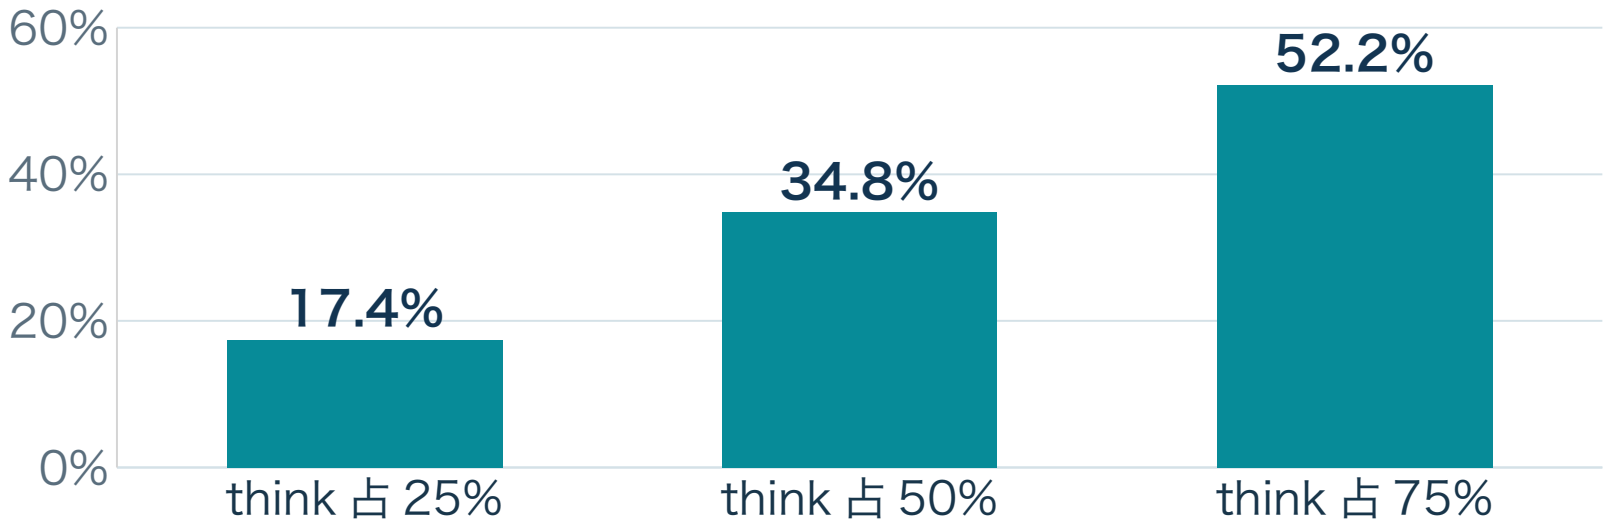
上述是请求工作量预算，只有落在关键路径上的部分才转为 episode 节省。

后续主例 ds_t2_par， 1 集 15 次有效请求。客户端时间戳实测窗口，不同于 v5 旧局。〔E3〕

MT low think： 阶段反馈与条件收益

4.6 s 降至 1.4 s

阶段指标差 3.2 s，下降 69.6%，阶段速度比约 3.29×



条件演算

其他成本不变，完整请求降幅约 69.6%×f 。

整集还受 N 影响

同口径均值、固定请求数和关键路径均需成立。

后续将 low 作为候选档位，先验证任务质量基本不降，再比较完整请求与整集成本。

E4 用户转述 MT 最新实验。质量、样本量、均值／中位数和时钟边界待补证。

候选优化矩阵：证据、风险与验收

候选方向	当前支持	主要风险	质量与成本验收
low ／ none 思考档位	medium/none 有小样本对照， MT 为 E4	动作质量、异常输出变化	配对成功、合法动作、请求与整集
payload ／上下文／缓存	文件引用、流式已有证据	裁剪丢信息、命中条件漂移	任务质量、输入量、命中与完整等待
调用粒度与事件触发	轮次、 π 块与恢复存在长尾	延迟发现偏差、局部恢复失效	成功、无进展轮、恢复代价、 AoI
Jev 有限选择	接口源码已核实 RPent 收益未验证	状态／候选生成 回退与额外调用成本	固定状态与候选比较，计完整链路
本地 π ／ NPU 调度	局部 handler 与探针可定位	共置干扰、过期动作	deadline 、 chunk gap 、整集关键路径

候选仍未选定。按共同质量门槛比较完整链路收益，并保留所有 attempt 成本。

候选路线尚未选定。共享输入、版本与质量判据，不把失败早停当作提速。〔接口 E1 ／方案 E3 〕

Astra ／ Jev ／ VLA： 四种架构候选

架构候选	职责分配	潜在收益	新增成本／约束
现有 Astra ＋技能 /VLA	Astra 按现有闭环调用 几何工具／ π 技能	保留现有基线	重复往返与恢复长尾
低频 Astra ＋ VLA	Astra 定阶段 VLA 执行有限动作块	减少高层调用	进展监测与过期动作
Jev 选择＋ VLA	外部提供状态／候选 Jev 选择， VLA 执行	有限选择器处理事件	状态／候选生成 回退与额外调用
Astra ＋ Jev ＋ VLA	Astra 感知和规划 Jev 选择， VLA 执行	分离规划与选择	候选错误与串行延迟

若 Astra 每轮仍先生成候选再串行调用 Jev ， 可能新增等待， 整体收益尚未验证。

规则／ Astra ／ Jev 固定状态与候选消融， 保持安全约束、触发条件和回退预算相同。

RPent 已有 π 技能。 Jev 为文本有限选择器， EmbodiedJev 数值伺服与 RPent 的 VLA 属不同实验链。〔 E1/E3 〕

技术趋势与局部实时性

工作	可借鉴机制	本项目验证点
Hi Robot	高层语言子任务与低层执行	子目标是否减少无效往返
Helix	S2/S1 异频与异步协同	观测年龄、阶段版本与触发
RTC	执行旧 chunk 时生成新 chunk	chunk 连续性与过期动作处理

局部窗口：384 ms / chunk ＞ 5 步 × 50 ms = 250 ms

本地 VLA 可优化算子与调度，仍需同时测 deadline 、 chunk gap 和设备共置。

云端 Astra/Jev 的可控项主要是输入、连接与调用策略，供应商内部计算保持未知。

官方机制借鉴，访问 2026-10-14 。固定帧 π 探针非在线 handler 均值，上游频率不可直接套用。〔E3〕

结论与质量门槛

阶段	可交付结果	晋级条件
证据补全	MT 同口径、 SSE 边界 逻辑请求与 attempt 标识	数字可追溯，质量和时钟定义明确
固定状态对照	档位、缓存、规则／ Jev 单次质量与延迟	动作合法，选择质量满足约定门槛
配对闭环比较	成功、完成质量、轮次、恢复与全部成本	质量基本不降且整集关键路径缩短
部署与实时验证	NPU 热点、共置、 Aol 与 chunk gap	局部 deadline 满足，质量收益能保留

已有成果：建立成功率、总账与请求窗口的分层证据，定位长程质量和等待长尾。

下一步：用共同质量门槛比较候选路线，再决定投入方向和部署方式。

质量基本不降，候选路线未定。没有足够样本时只报告区间与趋势，不承诺非劣性。〔E3 设计〕